



Kierunek: Automatyka i Robotyka

Specjalność: Informatyka Przemysłowa

Data urodzenia: 21.03.1993 r.

Data rozpoczęcia studiów: 23.02.2016 r.

Życiorys

Urodziłem się 21. marca 1993 roku w Lublinie. W 2012 roku rozpoczęłem studia inżynierskie I stopnia na Wydziale Mechatroniki Politechniki Warszawskiej, na kierunku Automatyka i Robotyka, na specjalności Informatyka Przemysłowa. Ukończył je 17 lutego 2016 roku. W tym samym roku rozpoczęłem studia II stopnia na tym samym wydziale, na specjalności Informatyka Przemysłowa.



POLITECHNIKA WARSZAWSKA

Wydział Mechatroniki

Praca magisterska

Ireneusz Szulc

Planowanie bezkolizyjnych tras dla zespołu robotów mobilnych

Promotor:
prof. nzw. dr hab. Barbara Siemiątkowska

Warszawa, 2018

PRACA DYPLOMOWA magisterska

Specjalność: Informatyka Przemysłowa

Instytut prowadzący specjalność: Instytut Automatyki i Robotyki

Instytut prowadzący pracę: Instytut Automatyki i Robotyki

Temat pracy: Planowanie bezkolizyjnych tras dla zespołu robotów mobilnych

Temat pracy (w jęz. ang.): Path planning for a group of mobile robots

Zakres pracy:

1. Projekt algorytmu wyznaczania trajektorii dla pojedynczego robota
2. Algorytm detekcji i zapobiegania kolizjom między robotami
3. Implementacja oprogramowania symulacyjnego
4. Przeprowadzenie testów symulacyjnych

Podstawowe wymagania:

1. Aplikacja powinna umożliwiać symulację ruchu robotów oraz definiowanie położenia przeszkód przez użytkownika.
2. Planowanie tras dotyczy robotów holonomicznych.

Literatura:

1. Mówiński K., Roszkowska E.: Sterowanie hybrydowe ruchem robotów mobilnych w systemach wielorobotycznych, Postępy Robotyki, 2016,
2. Siemiątkowska B.: Uniwersalna metoda modelowania zachowań robota mobilnego wykorzystująca architekturę uogólnionych sieci komórkowych, Warszawa 2009,
3. Silver D.: Cooperative Pathfinding, 2005

Słowa kluczowe: planowanie tras, systemy wielorobotowe

Praca dyplomowa jest realizowana we współpracy z przemysłem:

Nie

<i>Ireneusz Szulc</i> Imię i nazwisko dyplomanta:	Imię i nazwisko promotora: <i>Barbara Siemiątkowska</i>
	Imię i nazwisko konsultanta:
Temat wydano dnia:	Termin ukończenia pracy:

Zatwierdzenie tematu

<i>B. Smi</i> Opiekun specjalności	<i>K. Siemiątkowska</i> Z-ca Dyrektora Instytutu
--	--

Streszczenie

Planowanie bezkolizyjnych tras dla zespołu robotów mobilnych

TODO uzupełnić

Słowa kluczowe: planowanie tras, systemy wielorobotowe

Abstract

Path planning for a group of mobile robots

TODO przetłumaczyć

Key words: cooperative path-planning, multi-agent systems



„załącznik nr 3 do zarządzenia nr 24/2016 Rektora PW

.....
miejscowość i data

.....
imię i nazwisko studenta

.....
numer albumu

.....
kierunek studiów

OŚWIADCZENIE

Świadomy/-a odpowiedzialności karnej za składanie fałszywych zeznań oświadczam, że niniejsza praca dyplomowa została napisana przeze mnie samodzielnie, pod opieką kierującego pracą dyplomową.

Jednocześnie oświadczam, że:

- niniejsza praca dyplomowa nie narusza praw autorskich w rozumieniu ustawy z dnia 4 lutego 1994 roku o prawie autorskim i prawach pokrewnych (Dz.U. z 2006 r. Nr 90, poz. 631 z późn. zm.) oraz dóbr osobistych chronionych prawem cywilnym,
- niniejsza praca dyplomowa nie zawiera danych i informacji, które uzyskałem/-am w sposób niedozwolony,
- niniejsza praca dyplomowa nie była wcześniej podstawą żadnej innej urzędowej procedury związanej z nadawaniem dyplomów lub tytułów zawodowych,
- wszystkie informacje umieszczone w niniejszej pracy, uzyskane ze źródeł pisanych i elektronicznych, zostały udokumentowane w wykazie literatury odpowiednimi odnośnikami,
- znam regulacje prawne Politechniki Warszawskiej w sprawie zarządzania prawami autorskimi i prawami pokrewnymi, prawami własności przemysłowej oraz zasadami komercjalizacji.

Oświadczam, że treść pracy dyplomowej w wersji drukowanej, treść pracy dyplomowej zawartej na nośniku elektronicznym (płycie kompaktowej) oraz treść pracy dyplomowej w module APD systemu USOS są identyczne.

.....
czytelny podpis studenta”

Spis treści

Spis treści

1 Wprowadzenie	15
1.1 Cel i zakres pracy	15
1.2 Założenia	16
1.3 Zastosowanie koordynacji ruchu robotów	16
1.4 Podobieństwo do gier RTS	17
2 Wstęp teoretyczny	19
2.1 Podstawowe pojęcia	19
2.2 Kooperacyjne planowanie tras	19
2.3 Metoda pól potencjałowych	20
2.4 Rozproszone planowanie tras	20
2.5 Planowanie uwzględniające priorytety	22
2.6 Metoda Path Coordination	22
3 Algorytmy oparte o A*	25
3.1 Algorytm A*	26
3.1.1 Zasada działania	26
3.1.2 Funkcja heurystyczna	26
3.2 Metody ponownego planowania	28
3.2.1 Local Repair A*	28
3.2.2 Algorytm D*	29
3.2.3 D* Extra Lite	29
3.3 Cooperative A*	29
3.3.1 Trzeci wymiar - czas	30
3.3.2 Tablica rezerwacji	30
3.4 Hierarchical Cooperative A*	32

3.5	Windowed Hierarchical Cooperative A*	32
3.6	Podsumowanie metod kooperacyjnego planowania	34
4	Opracowanie i implementacja algorytmów	35
4.1	Generator map	35
4.2	Wyznaczanie trajektorii dla pojedynczego robota	39
4.3	Detekcja i przeciwdziałanie kolizjom	41
4.4	Implementacja algorytmu WHCA*	44
4.4.1	Tablica rezerwacji	44
4.4.2	Mozliwe akcje	45
4.4.3	Funkcja kosztu	45
4.4.4	Funkcja heurystyczna	46
4.4.5	Wybór najbardziej obiecującego rozwiązania	46
4.4.6	Uzyskane wyniki	47
4.5	Dynamiczny przydział priorytetów	48
4.5.1	Detekcja kolizji	49
4.5.2	Wariant WHCA*2	49
4.5.3	Wariant WHCA*3	50
4.6	Ograniczenia metod	51
5	Oprogramowanie symulacyjne	53
5.1	Funkcjonalności aplikacji	53
5.2	Graficzny interfejs użytkownika	54
5.2.1	Metoda pól potencjałowych	54
5.2.2	Local-Repair A*	55
5.2.3	Windowed Hierarchical Cooperative A*	57
5.3	Wykorzystane technologie	57
5.3.1	Java 8	57
5.3.2	JavaFX	59
5.3.3	Spring	59
5.3.4	jUnit i Test-driven development	60
5.3.5	Maven	60
5.3.6	IntelliJ IDEA	61
5.3.7	Pozostałe narzędzia i biblioteki	61
5.4	Struktura aplikacji	62
5.4.1	Wzorzec Model-View-Presenter	62

5.4.2	Wielowątkowość	63
6	Przeprowadzone testy	65
6.1	Automatyczne zarządzanie symulacjami	66
6.2	Środowiska testowe	67
6.3	Wyniki testów	70
6.3.1	Częstotliwość występowania potencjalnych kolizji	70
6.3.2	Wpływ wielkości okna czasowego	71
6.3.3	Skuteczność LRA* i WHCA* ³	72
6.3.4	Porównanie wariantów WHCA*	75
6.3.5	Wpływ rozmiaru mapy	75
6.3.6	Wpływ liczby robotów	79
6.3.7	Metoda pól potencjałowych	82
6.4	Dyskusja wyników	82
7	Podsumowanie	85
Bibliografia		87
Wykaz skrótów		91
Spis rysunków		93
Spis tabel		97
Spis załączników		99

Rozdział 1

Wprowadzenie

1.1 Cel i zakres pracy

Przedmiotem niniejszej pracy są metody wykorzystywane do planowania bezkolizyjnych tras dla wielu robotów mobilnych. Przegląd metod stanowi wstęp teoretyczny do zaprojektowania algorytmu i implementacji oprogramowania pozwalającego na symulację działania skutecznego planowania tras dla systemu wielorobotowego.

Praca skupia się na przypadkach, w których mamy do czynienia ze środowiskiem z dużą liczbą przeszkód (np. zamknięty budynek z licznymi ciasnymi korytarzami), aby uwypuklić problem blokowania się agentów często prowadzący do zakleszczenia. Często okazuje się, że należy wtedy zastosować nieco inne podejścia niż te, które sprawdzają się w przypadku otwartych środowisk, a które zostały opisane np. w pracach [8], [10]. W otwartych środowiskach z małą liczbą przeszkód wystarczające może się okazać np. proste ponowne planowanie wykorzystujące algorytm LRA* (por. 3.2.1) lub D* (por. 3.2.2).

W niniejszej pracy starano się znaleźć metody rozwiązuające zagadnienie, w którym znane są:

- pełna informacja o mapie otoczenia (położenie statycznych przeszkód),
- aktualne położenie i położenie celu każdego z robotów.

Szukany jest natomiast przebieg tras do punktów docelowych dla agentów. Zadaniem algorytmu będzie wyznaczenie możliwie najkrótszej bezkolizyjnej trasy dla wszystkich robotów. Należy jednak zaznaczyć, że priorytetem jest dotarcie każdego z robotów do celu bez kolizji z innymi robotami. Drugorzędne zaś jest, aby wyznaczone drogi były możliwie jak najkrótsze.

1.2 Założenia

Założenia i ograniczenia rozważanego problemu:

1. Każdy z robotów ma wyznaczony inny punkt docelowy, do którego zmierza.
2. Planowanie tras dotyczy mobilnych robotów holonomicznych.
3. Czas trwania zmiany kierunku robota jest pomijalnie mały.
4. Środowisko, w którym poruszają się roboty, jest dwuwymiarową przestrzenią zawierającą dużą liczbę przeszkód oraz wąskie korytarze (por. rys. 1.1).
5. Roboty "wiedzą" o sobie i mogą komunikować się ze sobą podczas planowania tras.
6. Każdy robot zajmuje w przestrzeni jedno pole. Na jednym polu może znajdować się maksymalnie jeden robot (por. rys. 1.1).
7. Planowanie tras powinno odbywać się w czasie rzeczywistym.



Rysunek 1.1: Przykładowe środowisko z dużą liczbą przeszkód (czarne kwadraty) i rozmieszczonymi robotami (kolorowe koła). Źródło: własna implementacja oprogramowania symulacyjnego

1.3 Zastosowanie koordynacji ruchu robotów

Koordynacja ruchu robotów jest jednym z fundamentalnych problemów w systemach wielorobotowych [1].

Kooperacyjne znajdowanie tras (ang. *Cooperative Pathfinding*) jest zagadnieniem planowania w układzie wieloagentowym, w którym to agenci mają za zadanie znaleźć bezkolizyjne drogi do swoich, osobnych celów. Planowanie to odbywa się w oparciu o pełną informację o środowisku oraz o trasach pozostałych agentów [11].

Algorytmy do wyznaczania bezkolizyjnych tras dla wielu agentów (robotów) mogą znaleźć zastosowanie w szpitalach (np. roboty TUG i HOMER do dostarczania sprzętu na wyposażeniu szpitala [24]) oraz magazynach (np. roboty transportowe w magazynach firmy Amazon - por. rys. 1.2).



Rysunek 1.2: Roboty Kiva pracujące w magazynie firmy Amazon. Źródło: [16]

1.4 Podobieństwo do gier RTS

Problem kooperacyjnego znajdowania tras pojawia się nie tylko w robotyce, ale jest również popularny m.in. w grach komputerowych (strategiach czasu rzeczywistego), gdzie konieczne jest wyznaczanie przez sztuczną inteligencję bezkolizyjnych dróg dla wielu jednostek, unikając wzajemnego blokowania się. Niestety brak wydajnych i skutecznych algorytmów planowania dróg można zauważać w wielu grach typu RTS (ang. *Real-Time Strategy*), gdzie czasami obserwuje się zjawisko zakleszczenia jednostek w wąskich gardłach (np. w grach *Age of Empires II*, *Warcraft III* lub nawet we współczesnych produkcjach) [4] (por. rys. 1.3). Ponadto, zauważalny brak ogólnie dostępnych bibliotek open-source do rozwiązania problemu typu *Cooperative Pathfinding* świadczy o potrzebie rozwoju tych metod.

Często algorytmy wykorzystywane w grach typu RTS (ang. *Real-Time Strategy*) zajmują się planowaniem bezkolizyjnych dróg dla układu wielu agentów w czasie rzeczywistym (będącego

przedmiotem niniejszej pracy), dlatego nic nie stoi na przeszkodzie, aby stosować je zamiennie również do koordynacji ruchu zespołu robotów mobilnych.



Rysunek 1.3: Popularny problem zakleszczania się jednostek w wąskich gardłach występujący w grach typu RTS. Źródło: gra komputerowa *Age of Empires II Forgotten Empires*

Rozdział 2

Wstęp teoretyczny

2.1 Podstawowe pojęcia

Definicja 2.1.1. Robot holonomiczny

Robot holonomiczny to taki robot mobilny, który może zmienić swoją orientację, stojąc w miejscu.

Definicja 2.1.2. Przestrzeń konfiguracyjna

Przestrzeń konfiguracyjna to N -wymiarowa przestrzeń będąca zbiorem możliwych stanów danego układu fizycznego. Wymiar przestrzeni zależy od rodzaju i liczby wyróżnionych parametrów stanu. W odróżnieniu od przestrzeni roboczej, gdzie robot ma postać bryły, w przestrzeni konfiguracyjnej robot jest reprezentowany jako punkt.

Definicja 2.1.3. Zupełność algorytmu (ang. *Completeness*)

W kontekście algorytmu przeszukiwania grafu algorytm zupełny to taki, który gwarantuje znalezienie rozwiązania, jeśli takie istnieje. Warto zaznaczyć, że nie gwarantuje to wcale, że znalezione rozwiązanie będzie rozwiązaniem optymalnym.

2.2 Kooperacyjne planowanie tras

Spośród metod wykorzystywanych do kooperacyjnego planowania tras dla wielu robotów można wyróżnić dwie zasadnicze grupy [7]:

- **Zcentralizowane** - drogi wyznaczane są dla wszystkich agentów na raz (jednocześnie). Metody tego typu są często trudne do zrealizowania (gdyż do rozwiązania jest złożony problem optymalizacyjny) oraz mają bardzo dużą złożoność obliczeniową ze względu

na ogólną przestrzeń przeszukiwania. Struktura organizacyjna jest skoncentrowana - decyzje podejmowane są na podstawie centralnego systemu.

- **Rozproszone** (ang. *decoupled* lub *distributed*) - podejście to dekomponuje zadanie na niezależne lub zależne w niewielkim stopniu problemy dla każdego agenta. Dla każdego robota droga wyznaczana jest osobno, w określonej kolejności, następnie rozwiązywane są konflikty (kolizje dróg). Zastosowanie metod rozproszonych wiąże się najczęściej z koniecznością przydzielania priorytetów robotom, co stanowi istotny problem, gdyż od ich wyboru może zależeć zupełność algorytmu. Nie należy mylić tej metody z zagadnieniem typu *Non-Cooperative Pathfinding*, w którym agenci nie mają wiedzy na temat pozostałych planów i muszą przewidywać przyszłe ruchy pozostałych robotów [11]. W podejściu rozproszonym agenci mają pełną информацию na temat stanu pozostałych robotów, lecz wyznaczanie dróg odbywa się w określonej kolejności.

W systemach czasu rzeczywistego istotne jest, aby rozwiązanie problemu planowania tras uzyskać w krótkim, deterministycznym czasie, dlatego w tego typu systemach częściej używane są techniki rozproszone.

2.3 Metoda pól potencjałowych

Metoda pól potencjałowych (ang. *Artificial Potential Field* lub *Potential Field Technique*) polega na zastosowaniu zasad oddziaływanego między ładunkami znanych z elektrostatyki. Roboty i przeszkody traktowane są jako ładunki jednoimienne, przez co "odpychają się" siłą odwrotnie proporcjonalną do kwadratu odległości (dzięki temu unikają kolizji między sobą). Natomiast punkt docelowy robota jest odwzorowany jako ładunek o przeciwnym biegunie, przez co robot jest "przyciągany" do celu. Główną zasadę działania metody przedstawiono na rysunku 2.1.

Technika ta jest bardzo prosta i nie wymaga wykonywania złożonych obliczeń (w odróżnieniu do pozostałych metod zcentralizowanych). Niestety bardzo powszechny jest problem osiągania minimum lokalnego, w którym suma wektorów daje zerową siłę wypadkową. Robot zostaje "uwięziony" w takim minimum lokalnym, przez co nie jest w stanie dotrzeć do wyznaczonego celu. Do omijania tego problemu muszą być stosowane inne dodatkowe metody [14]. Metoda pól potencjałowych nie daje gwarancji ani optymalności, ani nawet zupełności.

2.4 Rozproszone planowanie tras

Najczęściej stosowanymi podejściami są metody oparte o algorytm A* lub jego pochodne. W celu wykonywania wydajnych obliczeń w algorytmach przeszukujących grafy, nawet w przypadku



Rysunek 2.1: Zasada działania metod pól potencjałowych. Dodatni ładunek q_{start} reprezentuje robota. Przyciągany jest w stronę ujemnego ładunku celu q_{goal} , zaś odpychany jest od dodatnio naładowanej przeszkody. Źródło: [23]

ciągłej przestrzeni mapy, stosuje się podział na dyskretną siatkę pól (por. rys. 2.2) [3].



Rysunek 2.2: Ciągła przestrzeń mapy zdyskretyzowana do siatki pól.
Źródło: edytor map z gry Warcraft III.

Popularne podejścia unikające planowania w wysoko wymiarowej zbiorowej przestrzeni konfiguracyjnej to techniki rozproszone i uwzględniające priorytety [1]. Pomimo, że metody te są bardzo efektywne, mają dwie główne wady:

- Nie są zupełne - nie dają gwarancji znalezienia rozwiązania, nawet gdy takie istnieje.
- Wynikowe rozwiązania mogą być nieoptymalne.



Rysunek 2.3: Sytuacja, w której żadne rozwiązanie nie zostanie znalezione, stosując planowanie uwzględniające priorytety, jeśli robot 1 ma wyższy priorytet niż robot 2. Źródło: [1]

2.5 Planowanie uwzględniające priorytety

Często używaną w praktyce metodą jest planowanie z uwzględnianiem priorytetów. W tej technice agenci otrzymują unikalne priorytety. Algorytm wykonuje indywidualne planowanie sekwencyjnie dla każdego agenta w kolejności od najwyższego priorytetu. Trajektorie agentów o wyższych priorytetach są ograniczeniami (ruchomymi przeszkodami) dla pozostałych agentów [2].

Złożoność ogólnego algorytmu rośnie liniowo wraz z liczbą agentów, dzięki temu to podejście ma zastosowanie w problemach z dużą liczbą agentów. Algorytm ten jest zachłanny i niezupełny w takim znaczeniu, że agentów zadowala pierwsza znaleziona trajektoria niekolidująca z agentami wyższych priorytetów.

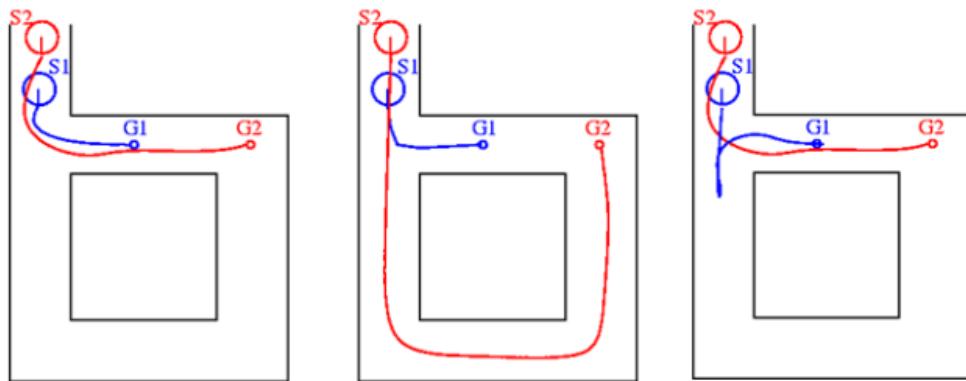
Istotną rolę doboru priorytetów robotów w procesie planowania tras ukazuje prosty przykład przedstawiony na rysunku 2.3. Jeśli robot 1 (zmierzający z punktu S1 do G1) otrzyma wyższy priorytet niż robot 2 (zmierzający z S2 do G2), spowoduje to zablokowanie przejazdu dla robota 2 i w efekcie prawidłowe, istniejące rozwiązanie nie zostanie znalezione.

Układ priorytetów może mieć także wpływ na długość uzyskanych tras. Potwierdzający to przykład został przedstawiony na rysunku 2.4. W zależności od wyboru priorytetów, wpływających na kolejność planowania tras, otrzymujemy różne rozwiązania.

2.6 Metoda Path Coordination

Jedną z metod rozproszonego planowania tras z uwzględnianiem priorytetów jest *Path Coordination*, której idea przedstawia się w następujących krokach [1]:

1. Wyznaczenie ścieżki dla każdego robota **niezależnie** (np. za pomocą algorytmu A*)
2. Przydział priorytetów
3. Próba rozwiązywania możliwych konfliktów między ścieżkami. Roboty utrzymywane są na ich indywidualnych ścieżkach (wyznaczonych na początku), wprowadzane modyfikacje



Rysunek 2.4: a) Niezależne planowanie optymalnych tras dla 2 robotów; b) suboptimalne rozwiązanie, gdy robot 1 ma wyższy priorytet; c) rozwiązanie, gdy robot 2 ma wyższy priorytet.
 Źródło: [1]

pozwalały na zatrzymanie się, ruch naprzód, a nawet cofanie się, ale tylko **wzdłuż trajektorii** w celu uniknięcia kolizji z robotem o wyższym priorytecie.

Rozdział 3

Algorytmy oparte o A*

Kiedy pojedynczy agent staje przed zadaniem znalezienia drogi do wyznaczonego celu, prosty algorytm A* sprawdza się znakomicie. Jednak w przypadku, gdy wiele agentów porusza się w tym samym czasie, podejście to może się już nie sprawdzić, powodując wzajemne blokowanie się i zakleszczenie jednostek. Rozwiązaniem tego problemu jest kooperacyjne znajdowanie tras. Dzięki tej technice roboty będą mogły skutecznie przemieszczać się przez mapę, omijając trasy wyznaczone przez inne jednostki oraz schodząc innym jednostkom z drogi, jeśli to konieczne [11].

Zagadnienie znajdowania drogi jest również ważnym elementem sztucznej inteligencji zaimplementowanej w wielu grach komputerowych. Chociaż klasyczny algorytm A* potrafi doprowadzić pojedynczego agenta do celu, to jednak dla wielu agentów wymagane jest zastosowanie innego podejścia w celu unikania kolizji. Istniejące rozwiązania są jednak wciąż oparte o Algorytm A*, choć nieco zmodyfikowany. Chociaż A* może zostać zaadaptowany do ponownego planowania trasy na żądanie, w przypadku wykrycia kolizji tras, to jednak takie podejście nie jest zadowalające pod wieloma względami. Na trudnych mapach z wieloma wąskimi korytarzami i wieloma agentami może to prowadzić do zakleszczenia agentów w wąskich gardłach lub do cyklicznego zapętlenia akcji agentów [11].

Rozdział ten zmierza do zaprezentowania zasady działania oraz cech algorytmu WHCA* (por. 3.5), zaproponowanego przez Davida Silvera [11]. Zaczynamy jednak od przedstawienia samego algorytmu A* i wprowadzając kolejne modyfikacje (CA*, HCA*), przekształcimy go stopniowo w WHCA*. W rozdziale zaprezentowano także rozwiązania alternatywne takie, jak: D* (por. 3.2.2) i LRA* (por. 3.2.1).

3.1 Algorytm A*

3.1.1 Zasada działania

A* jest algorytmem heurystycznym służącym do przeszukiwania grafu w celu znalezienia najkrótszej ścieżki między węzłem początkowym a węzłem docelowym. Algorytm ten jest powszechnie stosowany w zagadnieniach sztucznej inteligencji oraz w grach komputerowych [25]. Opiera się na zapisywaniu węzłów w dwóch listach: zamkniętych (odwiedzonych) i otwartych (do odwiedzenia). Jest modyfikacją algorytmu Dijkstry poprzez wprowadzenie pojęcia funkcji heurystycznej $h(n)$. Wartość funkcji heurystycznej powinna określać przewidywaną drogę do węzła docelowego z bieżącego punktu. Pełny koszt $f(n)$ stanowi sumę dotychczasowego kosztu $g(n)$ oraz przewidywanego pozostałoego kosztu.

$$f(n) = g(n) + h(n) \quad (3.1)$$

gdzie:

$g(n)$ - dotychczasowy koszt dotarcia do węzła n , dokładna odległość między węzłem n a węzłem początkowym

$h(n)$ - heurystyka, przewidywana pozostała droga od węzła bieżącego do węzła docelowego

$f(n)$ - oszacowanie pełnego kosztu ścieżki od węzła startowego do węzła docelowego prowadzącej przez węzeł n

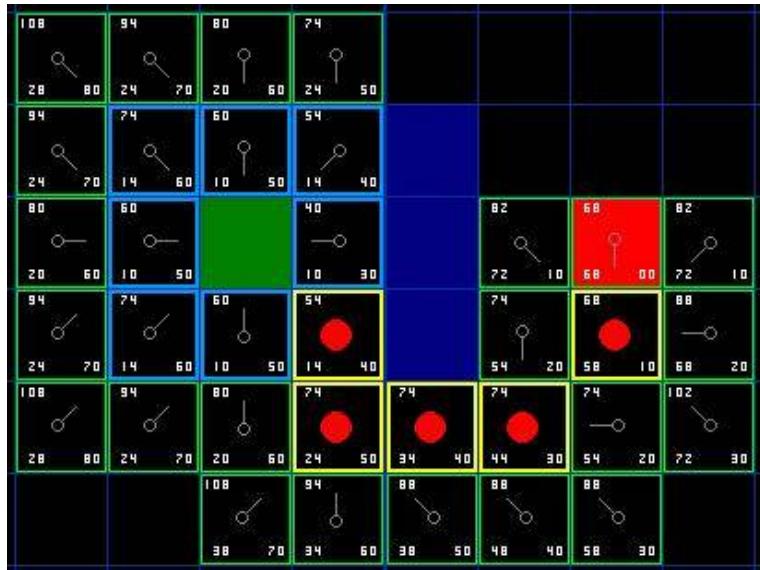
n - bieżący węzeł, wierzchołek przeszukiwanego grafu

W każdym kroku przeszukiwany jest węzeł o najmniejszej wartości funkcji $f(n)$. Dzięki takiemu podejściu najpierw sprawdzane są najbardziej "obiecujące" rozwiązania, co pozwala szybciej otrzymać wynik (w porównaniu do algorytmu Dijkstry). Algorytm kończy działanie w momencie, gdy napotka węzeł będący węzłem docelowym. Dla każdego odwiedzonego węzła zapamiętywane są wartości $g(n)$, $h(n)$ oraz węzeł będący rodzicem w celu późniejszego odnalezienia drogi powrotnej do węzła startowego po napotkaniu węzła docelowego (por. rys. 3.1).

Algorytm zwraca optymalny wynik (najkrótszą możliwą ścieżkę), ale w pewnych warunkach (por. 3.1.2).

3.1.2 Funkcja heurystyczna

Od wyboru sposobu obliczania heurystyki zależy czas wykonywania algorytmu oraz optymalność wyznaczonego rozwiązania.



Rysunek 3.1: Ilustracja wyznaczania działania przez A*. Każdy odwiedzony węzeł wskazuje na swojego rodzica, co umożliwia późniejszą rekonstrukcję drogi. Źródło: [15]

Definicja 3.1.1. Heurystyka dopuszczalna

Funkcja heurystyczna $h(n)$ jest dopuszczalna, jeśli dla dowolnego węzła n spełniony jest warunek:

$$h(n) \leq h^*(n) \quad (3.2)$$

gdzie:

$h^*(n)$ - rzeczywisty koszt ścieżki od węzła n do celu

Innymi słowy, heurystyka dopuszczalna to taka, która nigdy nie przeszacowuje pozostałą do przebycia drogi. Wtedy algorytm A* zwraca optymalną (najkrótszą) ścieżkę [11].

A* opiera się na heurystyce, która "kieruje" przeszukiwaniem. To od niej zależy, w kierunku których węzłów będzie podążało przeszukiwanie. Źle wybrana heurystyka może prowadzić do zbędnego odwiedzania dodatkowych węzłów.

Poniżej przedstawiono najczęściej wykorzystywane heurystyki będące oszacowaniem odległości między przeszukiwanym węzłem (x_n, y_n) a węzłem docelowym (x_g, y_g) na dwuwymiarowej mapie.

Heurystyka euklidesowa

Heurystyka wykorzystująca metrykę euklidesową wyraża dokładną odległość po linii prostej. Wymaga to jednak częstego obliczania pierwiastków (lub stosowania *look-up table*).

$$h(n) = \sqrt{(x_n - x_g)^2 + (y_n - y_g)^2} \quad (3.3)$$

Heurystyka Manhattan

W przypadku, gdy agent może poruszać się po mapie jedynie poziomo lub pionowo (nie na ukos) wystarczająca okazuje się metryka Manhattan (metryka miejska):

$$h(n) = |x_n - x_g| + |y_n - y_g| \quad (3.4)$$

Heurystyka metryki maksimum

Zastosowanie metryki maksimum (metryki Czebyszewa) może sprawdzić się np. dla niektórych figur szachowych:

$$h(n) = \max(|x_n - x_g|, |y_n - y_g|) \quad (3.5)$$

Heurystyka zerowa

Przyjęcie heurystyki równej $h(n) = 0$ sprawia, że algorytm A* sprowadza się do algorytmu Dijkstry.

3.2 Metody ponownego planowania

3.2.1 Local Repair A*

W algorytmie Local Repair A* (LRA*) każdy z agentów znajduje drogę do celu, używając algorytmu A*, ignorując pozostałe roboty oprócz ich obecnych sąsiadów. Roboty zaczynają podążać wyznaczonymi ścieżkami do momentu, aż kolizja z innym robotem jest nieuchronna (w lokalnym otoczeniu). Wtedy następuje ponowne przeliczenie drogi pozostałej do przebycia, z uwzględnieniem nowo napotkanej przeszkody.

Możliwe (i całkiem powszechnie [11]) jest uzyskanie cykli (tych samych sekwencji ruchów powtarzających się w nieskończoność), dlatego zazwyczaj wprowadzane są pewne modyfikacje, aby rozwiązać ten problem. Jedną z możliwości jest zwiększenie wpływów losowego szumu

na wartość heurystyki. Kiedy agenci zachowują się bardziej losowo, prawdopodobne jest, że wydostaną się z problematycznego położenia i spróbują podążać innymi ścieżkami.

Algorytm ten ma jednak sporo poważnych wad, które szczególnie ujawniają się w trudnych środowiskach z dużą liczbą przeszkód. Wydostanie się z zatłoczonego wąskiego gardła może trwać bardzo długo. Prowadzi to także do ponownego przeliczania trasy w prawie każdym kroku. Wciąż możliwe jest również odwiedzanie tych samych lokalizacji w wyniku zapętleń.

3.2.2 Algorytm D*

D* (*Dynamic A* Search*) jest przyrostowym algorytmem przeszukiwania. Jest modyfikacją algorytmu A* pozwalającą na szybsze ponowne planowanie trasy w wyniku zmiany otoczenia (np. zajmowania wolnego pola przez innego robota). Wykorzystywany jest m.in. w nawigacji robota do określonego celu w nieznanym terenie. Początkowo robot planuje drogę na podstawie pewnych założeń (np. nieznany teren nie zawiera przeszkód). Podążając wyznaczoną ścieżką, robot odkrywa rzeczywisty stan mapy i jeśli to konieczne, wykonuje ponowne planowanie trasy na podstawie nowych informacji. Często wykorzystywana implementacja (z uwagi na zoptymalizowaną złożoność obliczeniową) jest wariant algorytmu *D* Lite* [6].

3.2.3 D* Extra Lite

Wartym uwagi jest także algorytm *D* Extra Lite* charakteryzujący się jeszcze korzystniejszą wydajnością niż *D* Lite*, co potwierdziły przeprowadzone obszerne testy w różnego rodzaju środowiskach (m.in. na mapach z gier komputerowych oraz w zawiłych labiryntach) [9].

D Extra Lite* służy do przyrostowego planowania najkrótszej ścieżki w dwuwymiarowej przestrzeni bez dokładnej wiedzy o środowisku. Wykorzystanie wyników z poprzednich iteracji oraz wcześnie odrzucanie pewnych węzłów z drzewa przeszukiwania znacznie skracza czas potrzebny do wykonania ponownego planowania. *D* Extra Lite* jest nowatorskim algorytmem ogólnego przeznaczenia. Naturalnym jego zastosowaniem jest nawigacja robotów mobilnych [9].

3.3 Cooperative A*

Cooperative A* jest algorytmem do rozwiązywania problemu kooperacyjnego znajdowania tras. Metoda może być również nazywana czasoprzestrzennym algorytmem A* (*time-space A* search*). Zadanie planowania jest rozdzielone na serię pojedynczych poszukiwań dla poszczególnych agentów. Pojedyncze poszukiwania są wykonywane w trójwymiarowej czasoprzestrzeni i biorą pod uwagę zaplanowane ścieżki przez pozostałych agentów. Akcja wykonania postoju (pozostania w tym samym miejscu) jest uwzględniona w zbiorze akcji możliwych do wykonania. Po

przeliczeniu dróg dla każdego agenta, stany zajętości pól są zaznaczane w tablicy rezerwacji (ang. Reservation table). Pozycje w tej tablicy są uważane jako pola nieprzejezdne i w efekcie są omijane podczas przeszukiwania przez późniejszych agentów [11].

Należy zaznaczyć, że planowanie dla każdego agenta odbywa się sekwencko według przydzielonych priorytetów. Algorytm ten jest podatny na zmianę kolejności agentów. Odpowiedni dobór priorytetów może wpłynąć na wydajność algorytmu oraz jakość uzyskanego wyniku.

3.3.1 Trzeci wymiar - czas

Do rozwiązania problemu kooperacyjnego znajdowania dróg algorytm przeszukiwania potrzebuje mieć pełną wiedzę na temat przeskódeł oraz jednostek na mapie. Aby zapisać tą informację, potrzeba rozszerzyć mapę o trzeci wymiar - czas. Pierwotną mapę będziemy nazywać mapą przestrzenną, natomiast nową - czasoprzestrzenną mapą [11].

Zagadnienie sprowadza się do przeszukiwania grafu, w którym każdy węzeł ma przypisane 3 wielkości: położenie x, położenie y oraz czas. Podczas gdy zakres wielkości x i y jest znany i wynika z rozmiarów mapy oraz podziału jej wymiarów na dyskretne pola, to jednak określenie wymiaru czasu i jego granicy nie jest trywialnym zagadnieniem. Wymiar czasu możemy również zdyskretyzować i przyjąć, że krok czasu jest okresem, jaki zajmuje robotowi przejście z jednego pola na sąsiednie (poziomo lub pionowo). Natomiast górną granicą czasu powinna być maksymalna liczba ruchów potrzebna do dotarcia do celu przez ostatniego robota. Wybór za małej liczby może spowodować, że algorytm nie zdąży znaleźć drogi dla niektórych agentów, z kolei zbyt duża granica kroków czasu znacząco wydłuża obliczenia. Rozwiążanie tego problemu zostało opisane w późniejszym podrozdziale 3.5.

Wprowadzenie trzeciego wymiaru wprowadza także konieczność zmian w doborze odpowiedniej heurystyki odpowiedzialnej za oszacowanie drogi pozostałe do celu.

3.3.2 Tablica rezerwacji

Tablica rezerwacji (ang. *Reservation Table*) reprezentuje współdzieloną wiedzę o zaplanowanych ścieżkach przez wszystkich agentów. Jest to informacja o zajętości każdej z komórk na mapie w danym miejscu i określonym czasie [11]. Jak tylko agent zaplanuje trasę, każda komórka odpowiadająca ścieżce zaznaczana jest jako zajęta w tablicy rezerwacji.

W prostej implementacji tablica rezerwacji jest trójwymiarową kostką (dwa wymiary przestrzenne i jeden wymiar czasu). Każda komórka kostki, która jest przecinana przez zaplanowaną przez agenta ścieżkę, jest zaznaczana jako nieprzejezdna przez określony czas trwania. W ten sposób zapobiega to planowania kolizyjnych tras przez pozostałych agentów. (por. rys. 3.2)



Rysunek 3.2: Dwie jednostki kooperacyjnie poszukujące tras. (A) Pierwsza jednostka znajduje ścieżkę i zaznacza ją w tablicy rezerwacji. (B) Druga jednostka znajduje ścieżkę, uwzględniając istniejące rezerwacje pól, również zaznaczając ją w tablicy rezerwacji. Źródło: [11]

Jeśli tylko niewielka część z całej tablicy rezerwacji będzie markowana jako zajęta, wydajniej jest zaimplementować ją jako tablicę typu *hash table*. Daje to zaletę oszczędności pamięci poprzez pamiętanie jedynie współrzędnych (x, y, t) zajętych pól.

W ogólności poszczególni agenci mogą mieć różną prędkość lub rozmiary, zatem tablica rezerwacji musi mieć możliwość zaznaczenia dowolnego zajętego obszaru. Zostało to przedstawione na rysunku 3.3.



Rysunek 3.3: Tablica rezerwacji jest współdzielona między wszystkimi agentami. Jej rozmiar powinien być odpowiednio dopasowany do agentów o różnych prędkościach. Źródło: [11]

Niestety powyższy sposób wykorzystania tablicy rezerwacji w pewnych sytuacjach nie zapobiega zderzeniom czołowym jednostek zmierzających w przeciwnych kierunkach. Jeśli jedna jednostka zarezerwowała komórki (x, y, t) i $(x + 1, y, t + 1)$, nic nie stoi na przeszkodzie, aby kolejna jednostka mogła zarezerwować komórki $(x + 1, y, t)$ i $(x, y, t + 1)$. Ten problem może być rozwiązywany poprzez zajmowanie (rezerwowanie) dwóch sąsiednich komórek w tym samym czasie t podczas ruchu robota, a nie tylko jednej komórki.

3.4 Hierarchical Cooperative A*

Metoda *Hierarchical Cooperative A** (HCA*) wprowadza pewną modyfikację do algorytmu Cooperative A*. Modyfikacja ta dotyczy heurystyki opartej na abstrakcjach przestrzeni stanu [11]. HCA* jest także jednym z przykładów rozproszonego podejścia do planowania tras.

W tym podejściu abstrakcja przestrzeni stanu oznacza zignorowanie wymiaru czasu, jak również tablicy rezerwacji. Innymi słowy, abstrakcja jest prostą dwuwymiarową mapą z usuniętymi agentami. Abstrakcyjne odległości mogą być rozumiane jako dokładne oszacowania odległości do celu, ignorując potencjalne interakcje z innymi agentami. Jest to oczywiście dopuszczalna heurystyka (por. 3.1.2). Niedokładność heurystyki wynika jedynie z trudności związanych z interakcją z innymi agentami (jak bardzo agent musi zboczyć z pierwotnie zaplanowanej ścieżki w celu ominięcia innych agentów).

Do wyznaczenia heurystyki dla abstrakcyjnej przestrzeni stanu opisywane podejście wykorzystuje algorytm przeszukiwania *Reverse Resumable A** (RRA*). Algorytm ten wykonuje zmodyfikowane przeszukiwanie A* w odwrotnym kierunku. Przeszukiwanie zaczyna się w węźle docelowym agenta i kieruje się do początkowego położenia. Jednak zamiast kończyć w tym punkcie, przeszukiwanie jest kontynuowane do natrafienia na węzeł N , w którym znajduje się agent.

Algorytm HCA* jest więc taki, jak algorytm CA*, ale z bardziej wyszukaną heurystyką, która używa RRA* do obliczania abstrakcyjnych odległości na żądanie.

3.5 Windowed Hierarchical Cooperative A*

Problematyczne zagadnienie związane z wyżej wspomnianymi algorytmami jest takie, że kończą one działanie w momencie, gdy agent osiąga swój cel. Jeśli agent znajduje się już w miejscu docelowym, np. w wąskim korytarzu, to może on blokować części mapy dla innych agentów. W takiej sytuacji agenci powinni kontynuować kooperację z pozostałymi jednostkami, nawet po osiągnięciu swoich celów. Może to zostać zrealizowane np. poprzez usunięcie się z wąskiego gardła w celu przepuszczenia pozostałych agentów, a następnie powrót do docelowego punktu [11].

Kolejny problem związany jest z wrażliwością na kolejność agentów (przydzielone priorytety). Chociaż czasem możliwy jest skuteczny, globalny przydział priorytetów [7], to jednak dobrym rozwiązaniem może być dynamiczne modyfikowanie kolejności agentów. Wtedy rozwiązania mogą zostać znalezione w tych przypadkach, w których zawiodło przydzielanie niezmiennych priorytetów [11].

Rozwiązaniem powyższych kwestii jest zamknięcie algorytmu przeszukiwania w oknie cza-

sowym. Kooperacyjne planowanie jest ograniczone do ustalonej głębokości. Każdy agent szuka częściowej ścieżki do celu i zaczyna nią podążać. W regularnych okresach (np. gdy agent jest w połowie drogi) okno jest przesuwane dalej i wyznaczana jest nowa ścieżka.

Aby zapewnić, że agenci podążają do prawidłowych punktów docelowych, ograniczana jest tylko głębokość przeszukiwania kooperacyjnego (związanego z wieloma agentami), podczas gdy przeszukiwanie abstrakcyjnych odległości (heurystyki opisanej w podrozdziale 3.4) odbywa się bez ograniczeń głębokości. Okno o rozmiarze w może być rozumiane jako pośrednia abstrakcja, która jest równoważna wykonaniu w kroków w rzeczywistym środowisku (z uwzględnieniem pozostałych agentów) a następnie wykonaniu pozostałych kroków zgodnie z abstrakcją (bez uwzględnienia innych agentów). Innymi słowy, pozostały agenci są jedynie rozważani dla w pierwszych kroków (poprzez tablicę rezerwacji) a dla pozostałych kroków są ignorowani [11].

Rozmiar okna jest wielkością ustalaną arbitralnie. Rozmiar okna powinien być przyjęty jako czas trwania najdłuższego przewidywanego wąskiego gardła (zatoru). Dobrą praktyką jest przyjęcie wartości równej liczbie agentów na mapie, gdyż to właśnie z ich powodów mogą wystąpić ewentualne zmiany w zaplanowanej trasie.

Porównanie HCA* i WHCA*

Algorytm HCA* wybiera ustaloną kolejność agentów i planuje trasy dla każdego agenta po kolei, unikając kolizji z poprzednio wyznaczonymi ścieżkami. Natomiast użycie przeszukiwania z przesuwany oknem w WHCA* poprawia skuteczność algorytmu oraz przyspiesza proces wyznaczania rozwiązania [12].

Fakt wykonywania przeszukiwania w oknie oznacza, że planowanie algorytmem WHCA* wykonywane jest zawsze z ustaloną liczbą kroków w przyszłości i wybierany jest najbardziej obiecujący węzeł na granicy tego okna [13]. W metodach Hierarchical Cooperative A* oraz Cooperative A* wybór granicy wymiaru czasu (głębokości przeszukiwania w liczbie kroków) stanowi balans pomiędzy wydajnością a zupełnością algorytmu.

W obu podejściach HCA* i WHCA* zastosowano dodatkowy algorytm przeszukiwania wstecz (RRA*) wspomagający heurystykę. Służy on wyznaczeniu dokładnej odległości z węzła do celu, pomijając wpływ innych agentów. Jest to często heurystyka wysokiej jakości (prawie idealne oszacowanie), gorzej sprawdza się jedynie w środowiskach z dużą ilością wąskich gardeł i zatorów [13].

Chociaż takie przeszukiwanie wstecz prowadzi do początkowego wykonania większej ilości obliczeń (wykonanie pełnego przeszukania A* z punktu docelowego do punktu startowego, jak również do innych węzłów), to jednak koszt obliczeniowy w kolejnych krokach jest już zdecydowanie niższy [13].

3.6 Podsumowanie metod kooperacyjnego planowania

Większość popularnych algorytmów wykorzystywanych do planowania tras dla wielu robotów mobilnych (agentów) opiera się o A*.

Kooperacyjne planowanie tras jest ogólną techniką koordynacji dróg wielu jednostek. Znajduje zastosowanie, gdzie wiele jednostek może komunikować się ze sobą, przekazując informację o ich ścieżkach. Poprzez planowanie wprzód w czasie, jak również i w przestrzeni, jednostki potrafią schodzić sobie z drogi nawzajem w celu uniknięcia kolizji. Metody kooperacyjnego planowania są bardziej skuteczne i znajdują trasy wyższej jakości niż te uzyskane przez A* z metodą *Local Repair*.

Wiele z udoskonaleń przestrzennego algorytmu A* może być również zaadaptowane do czasoprzestrzennego A*. Ponadto, wprowadzenie wymiaru czasu otwiera nowe możliwości do rozwoju algorytmów znajdowania dróg.

Najbardziej obiecującym pod względem skuteczności algorytmem wydaje się być metoda WHCA*.

Aby wydajnie prowadzić obliczenia, zakłada się, że każdy ruch robota trwa tyle samo. Wprowadzi to upraszczające, błędne założenie, że ruch robota na pole w kierunku poziomym lub pionowym trwa tyle samo, co na ukos.

W wielu przypadkach metody do planowania bezkolizyjnych tras w systemach wieloagentowych mogą być wykorzystywane zamiennie zarówno do wyznaczania trajektorii robotów mobilnych, jak i w grach komputerowych, np. strategiach czasu rzeczywistego do planowania tras wielu jednostek.

Zaprezentowane algorytmy mogą znaleźć zastosowanie również w środowiskach z ciągłą przestrzenią oraz w dynamicznych środowiskach, w których to ścieżki muszą być przeliczane po wykryciu zmiany na mapie.

Rozdział 4

Opracowanie i implementacja algorytmów

Na potrzeby stworzenia oprogramowania symulacyjnego do planowania bezkolizyjnych tras dla wielu robotów mobilnych należało opracować lub zaimplementować niezbędne algorytmy.

W tym rozdziale opisano algorytmy, które znalazły zastosowanie w stworzonej aplikacji symulującej ruchy robotów mobilnych i zostały zaimplementowane samodzielnie. Należą do nich:

- Generator labiryntów (por. 4.1),
- Algorytm A* (por. 4.2),
- Algorytm LRA* (por. 4.3),
- Algorytm WHCA* (por. 4.4),
- Procedury obsługi dynamicznego przydzielania priorytetów oraz rozmiaru okna czasowego (por. 4.5).

4.1 Generator map

W rozdziale 6 opisano wyniki testów przeprowadzonych na losowo wygenerowanych środowiskach. Do ich automatycznego utworzenia wykorzystano własny generator map, który zapewnia im pewne pożądane własności opisane poniżej.

Zastosowanie zwykłego losowania położenia przeszkołd na mapie mogłoby spowodować, że do niektórych obszarów na mapie nie udałoby się znaleźć drogi, nawet mimo braku istnienia

pozostałych agentów. Takie środowisko nie miałoby sensownego zastosowania w praktyce, w kooperacyjnym znajdowaniu tras.

Zależy nam, aby uzyskać środowisko cechujące się dużą liczbą przeszkód i wąskimi korytarzami, aby uwypuklić problem występowania wąskich gardeł. Jednocześnie chcemy, aby istniała możliwość przejścia między dwoma dowolnymi punktami na mapie. Do rozwiązania problemu wygenerowania takich labiryntów posłużymy się teorią grafów i pojęciem grafu spójnego.

Definicja 4.1.1. Graf spójny

Graf spójny spełnia warunek, że dla każdej pary wierzchołków istnieje łącząca je ścieżka.

Układ pól na mapie będziemy reprezentować jako graf. W naszym przypadku wszystkie przejezdne pola na mapie są wierzchołkami grafu. Natomiast połączenia między sąsiednimi przejezdnymi polami (między którymi istnieje możliwość bezpośredniego przejścia) są krawędziami w grafie.

Aby zapewnić, że powstały graf będzie spójny, na początku losujemy jedno pole będące ziarnem rozrostu labiryntu, a następnie do takiego podgrafa dołączamy kolejne wierzchołki, łącząc je drogą na mapie. Krok ten powtarzamy do momentu, aż wszystkie wierzchołki zostaną dołączone. W tym celu wykorzystamy dwie pomocnicze listy wierzchołków:

- lista wierzchołków *odwiedzonych* - zawiera wierzchołki (pola) należące już do grafu tworzącego labirynt. Między wszystkimi wierzchołkami z listy *odwiedzonych* istnieje łącząca je droga - tworzą one graf spójny.
- lista wierzchołków *nieodwiedzonych* - zawiera nieodwiedzone wierzchołki (pola), które nie zostały jeszcze dołączone do labiryntu.

Kolejne kroki proponowanego algorytmu przedstawiają się następująco:

1. Inicjalizacja pustych list wierzchołków: *odwiedzonych* i *nieodwiedzonych*.
2. Zapełnienie całej mapy przeszkodami. Następnie, zaznaczenie co drugiego pola (wzdłuż każdego z wymiarów) jako wolne (por. rys. 4.1a) i dodanie ich do listy *nieodwiedzonych*.
3. Wylosowanie ziarna rozrostu labiryntu z listy *nieodwiedzonych*, przeniesienie go na listę *odwiedzonych*.
4. Łączenie kolejnych wierzchołków nieodwiedzonych z wierzchołkami odwiedzonymi. Dopóki lista *nieodwiedzonych* nie jest pusta:
 - (a) Wylosowanie wierzchołka z listy *nieodwiedzonych*.



Rysunek 4.1: Kolejne etapy generowania labiryntu: (a) Zaznaczenie co drugiego pola jako wolne i wybór ziarna rozrostu labiryntu. (b) Wylosowanie i łączenie kolejnego wierzchołka poprzez "wyburzanie" przeszkód na drodze (c) Wynikowa mapa pochodząca z generatora

- (b) Znalezienie najbliższego dla niego (w sensie metryki miejskiej) sąsiada z listy *odwiedzonych*.
- (c) Połączenie wierzchołków drogą poprzez "wyburzanie" przeszkód (zaznaczania pola jako wolne), przesuwając się w kierunku wierzchołka docelowego, najpierw wzdłuż osi poziomej, następnie wzdłuż osi pionowej (por. rys. 4.1b).

Pojedyncze dołączanie kolejnych wierzchołków do rozrastającego się grafu labiryntu zapewnia, że wynikowy graf również będzie grafem spójnym.

Algorytm 4.1.1 przedstawia pseudokod, obrazujący szczegóły działania zaprojektowanej metody.

Wyrażenie $x++$ oraz $x--$ oznacza odpowiednio postinkrementację oraz postdekrementację (dokonanie zwiększenia lub zmniejszenia o 1 **po** wykorzystaniu wartości zmiennej w wyrażeniu). Funkcja **ZNAJDŹ NAJBLIŻSZEGO SĄSIADA** wyszukuje sąsiada dla pola *nowePole* z listy *odwiedzone*. Wynik wyszukiwania jest najbliższy w sensie metryki miejskiej (metryki Manhattan).

Kolejne etapy generowania labiryntu zobrazowano na rysunku 4.1.


Na rysunku 4.2 przedstawiono przykładowy labirynt wygenerowany opisanym algorytmem.

Warto zaznaczyć, że łączenie kolejnych wierzchołków do najbliższego sąsiada nadaje pewną właściwość wygenerowanym mapom. Bardzo często (choć nie zawsze) między dwoma polami tworzy się tylko jedna łącząca je ścieżka (nie ma alternatywnych ścieżek). Sprzyja to tworzeniu się wąskich gardeł na mapie.

Wygenerowane w ten sposób mapy mają jeszcze jedną właściwość - w takim środowisku

Algorytm 4.1.1 Generowanie labiryntu

```
1: function GENERUJLABIRYNT(w, h) // w - szerokość mapy, h - wysokość mapy
2:   mapa[][] ← nowa tablica w × h wypełniona wartościami ZABLOKOWANE
3:   nieodwiedzone ← Ø, odwiedzone ← Ø // inicjalizacja pustych list
4:   for x ← 0; x < w; x ← x + 2 do // co drugi indeks szerokości
5:     for y ← 0; y < h; y ← y + 2 do // co drugi indeks wysokości
6:       mapa[x][y] ← WOLNE
7:       dodaj mapa[x][y] do nieodwiedzone
8:     end for
9:   end for
10:  ziarno ← losowe pole z nieodwiedzone
11:  dodaj ziarno do odwiedzone // przeniesienie do odwiedzone
12:  usuń ziarno z nieodwiedzone
13:  while nieodwiedzone ≠ Ø do // dopóki nieodwiedzone nie jest pusta
14:    nowePole ← losowe pole z nieodwiedzone
15:    sasiad ← ZNAJDŹNAJBŁIŻSZEGOSĄSIADA(odwiedzone, nowePole)
16:    WYBURZDROGĘ(mapa, nowePole, sasiad) // przeniesienie do odwiedzone
17:    dodaj nowePole do odwiedzone
18:    usuń nowePole z nieodwiedzone
19:  end while
20:  return mapa[]
21: end function
22:
23: function WYBURZDROGĘ(mapa, poleZ, poleDo)
24:   x ← poleZ.x
25:   y ← poleZ.y
26:   while x < poleDo.x do // przesuwanie w prawo
27:     mapa[x++][y] ← WOLNE // zwiększenie x
28:   end while
29:   while x > poleDo.x do // przesuwanie w lewo
30:     mapa[x--][y] ← WOLNE // zmniejszenie x
31:   end while
32:   while y < poleDo.y do // przesuwanie w dół
33:     mapa[x][y++] ← WOLNE // zwiększenie y
34:   end while
35:   while y > poleDo.y do // przesuwanie w górę
36:     mapa[x][y--] ← WOLNE // zmniejszenie y
37:   end while
38: end function
```



Rysunek 4.2: Przykładowy labirynt rozmiaru 75×75 pochodzący z zaprojektowanego generatora map

robot nie ma nigdy możliwości wykonania ruchu ukośnego (innego niż w poziomie lub pionie). Pozwaliłoby to wprowadzić pewne ograniczenia do niektórych algorytmów planowania (por. 3.3), które to przyspieszyłyby wykonywanie obliczeń ze względu na możliwość założenia jednakowego czasu trwania wszystkich ruchów robotów. Nie będziemy jednak tego zakładać na tym etapie, gdyż chcemy, aby opracowana metoda planowania tras mogła także działać w środowiskach o innym charakterze.

4.2 Wyznaczanie trajektorii dla pojedynczego robota

Wiele technik planowania tras, mimo iż może posłużyć do koordynacji ruchu wielu robotów, korzysta z metod indywidualnego planowania dla każdego agenta z osobna. Przykładem takiego podejścia jest *Local-Repair A**, w którym to głównym algorytmem przeszukującym jest A*. Z tego powodu przed przystąpieniem do opracowania bardziej skomplikowanych metod, należy najpierw zająć się implementacją algorytmu poszukiwania najkrótszej drogi na dwuwymiarowej mapie z jednym robotem. Wymagane jest to nawet dla metody WHCA*, która pomimo, że operuje na węzłach określonych w czasie i przestrzeni, to jednak w obliczaniu samej heurystyki wykorzystuje przestrzenny algorytm A*. Ogólna zasada działania algorytmu A* wraz z

kluczowymi pojęciami została opisana w rozdziale 3.1.

Pseudokod 4.2.1 oraz opisy użytych pomocniczych funkcji ukazują szczegóły implementacji metody wyznaczania najkrótszej drogi na przestrzennej mapie. Algorytm oparty jest o A*, jednak posiada pewne własne, niewielkie modyfikacje.

Algorytm 4.2.1 Algorytm A*

```

1: function ZNAJDZDROGĘ(mapa, start, cel)
2:   closed  $\leftarrow \emptyset$                                 // pusta lista zamkniętych
3:   open  $\leftarrow \{start\}$                             // lista otwartych zawiera punkt startowy
4:   for węzel  $\in$  mapa do
5:     węzel.g  $= \infty$                          // domyślnie nieskończony koszt - odległość od startu
6:   end for
7:   start.g  $\leftarrow 0$                            // Zerowy koszt przejścia do węzła startowego
8:   while open  $\neq \emptyset$  do                // dopóki lista otwartych nie jest pusta
9:     obecny  $\leftarrow$  ZNAJDŹMINF(open)        // Szukamy pola o najniższej wartości f
10:    if obecny  $= cel$  then
11:      return ZBUDUJŚCIEŻKĘ(cel)           // Znaleziono ścieżkę
12:    end if
13:    dodaj obecny do closed                 // Przesunięcie z open do closed
14:    usuń obecny z open
15:    for sasiad  $\in$  SĄSIEDZI(obecny) do    // Dla każdego sąsiada aktualnego pola
16:      if mapa[sasiad.x][sasiad.y] == ZABLOKOWANE or
17:        not PRZEJŚCIEPOPRAWNE(obecny, sasiad) then
18:          continue                                // Ignoruj niepoprawne pola lub przejścia
19:        end if
20:        nowyKoszt  $\leftarrow$  obecny.g + KOSZTPRZEJŚCIA(obecny, sasiad)
21:        if nowyKoszt < sasiad.g then            // znaleziono korzystniejsze połączenie
22:          usuń sasiad z open                  // konieczność ponownego przeliczenia
23:          usuń sasiad z closed                // jeśli sasiad  $\in$  open lub sasiad  $\in$  closed
24:        end if
25:        if sasiad  $\notin$  open  $\wedge$  sasiad  $\notin$  closed then
26:          sasiad.g  $\leftarrow$  nowyKoszt             // zapisanie nowego połączenia
27:          sasiad.h  $\leftarrow$  HEURYSTYKA(sasiad, cel)
28:          sasiad.parent  $\leftarrow$  obecny           // pole obecny rodzicem dla pola sasiad
29:          dodaj sasiad do open
30:        end if
31:      end for
32:    end while
33:    return  $\emptyset$                             // Przeanalizowano wszystkie węzły, brak istniejącej ścieżki
34: end function

```

Wykorzystane zostały pomocnicze funkcje:

- ZNAJDŹMINF(*lista*) - Funkcja zwraca z listy pole o najniższej wartości *f* (sumie kosztu i heurystyki);

- **ZBUDUJŚCIEŻKE(*cel*)** - Funkcja zwraca ścieżkę z punktu startowego do punktu *cel* zbudowaną na podstawie przechodzenia wstecz od punktu *cel* po kolejnych rodzicach węzłów, aż do dotarcia do węzła bez rodzica (punktu startowego).
- **SĄSIEDZI(*pole*)** - Funkcja zwraca zbiór pól bezpośrednio sąsiadujących (dla których istnieje możliwość przejścia) ze wskazanym polem. Jest to zazwyczaj zbiór ośmiu sąsiadujących pól. Na granicach mapy należy uwzględnić warunki brzegowe.
- **PRZEJŚCIEPOPRAWNE(*poleZ*, *poleDo*)** - Funkcja zwraca prawdę wtedy i tylko wtedy, gdy istnieje możliwość przejścia z *poleZ* do *poleDo*. Gdy wykonywany jest ruch ukośny, ale na przynajmniej jednym polu sąsiadującym z *poleZ* i *poleDo* znajduje się przeszkoda, to taki ruch jest niepoprawny. Ruch ukośny agenta z punktu (x_1, y_1) do (x_2, y_2) możliwy jest tylko w przypadku, gdy na żadnym z czterech pól: (x_1, y_1) , (x_2, y_1) , (x_1, y_2) , (x_2, y_2) nie znajduje się przeszkoda. W rzeczywistym środowisku zabezpiecza to robota przed uderzeniem o wystający róg ściany.
- **KOSZTPRZEJŚCIA(*poleZ*, *poleDo*)** - Funkcja zwraca koszt przejścia z *poleZ* do *poleDo*. Jest to odległość w sensie metryki euklidesowej.
- **HEURYSTYKA(*poleZ*, *poleDo*)** - Funkcja zwraca przewidywaną długość pozostałej drogi od *poleZ* do *poleDo*. Jest to również odległość euklidesowa.

Potwierdzeniem poprawności zaimplementowania algorytmu wyznaczania najkrótszej ścieżki jest przykładowa droga przedstawiona na rysunku 4.3 pochodzący z aplikacji. Warto zauważyć, że możliwy jest ruch ukośny robota, ale nie taki, który powodowałby kolizję z wystającym rogiem "ściany".

4.3 Detekcja i przeciwdziałanie kolizjom

Do zademonstrowania prostego przeciwdziałania kolizjom robotów wykorzystano metodę LRA* (*Local-Repair A**). W rozdziale tym opisano własną implementację tej metody. Należy zaznaczyć, że jest to bardzo uproszczone podejście i stanowi wstęp do bardziej złożonego algorytmu. Duże skuteczniejsza w zapobieganiu kolizji jest metoda WHCA* (por. 4.4) z dynamicznym przydziałem priorytetów (por. 4.5), która została opisana w późniejszych rozdziałach.

Przez kolizję będziemy rozumieć sytuację, w której przynajmniej 2 roboty przebywają w tym samym miejscu (na tym samym polu) i w tym samym czasie (w tym samym kroku czasowym). Warto dodać, że dopuszczalne jest przecinanie się trajektorii robotów w różnym czasie.



Rysunek 4.3: Przykładowa ścieżka wyznaczona przez zaimplementowany w aplikacji algorytm A*. Kolorowe koło reprezentuje robota, linia łamana - wyznaczoną ścieżkę, czarne kwadraty - przeszkody.

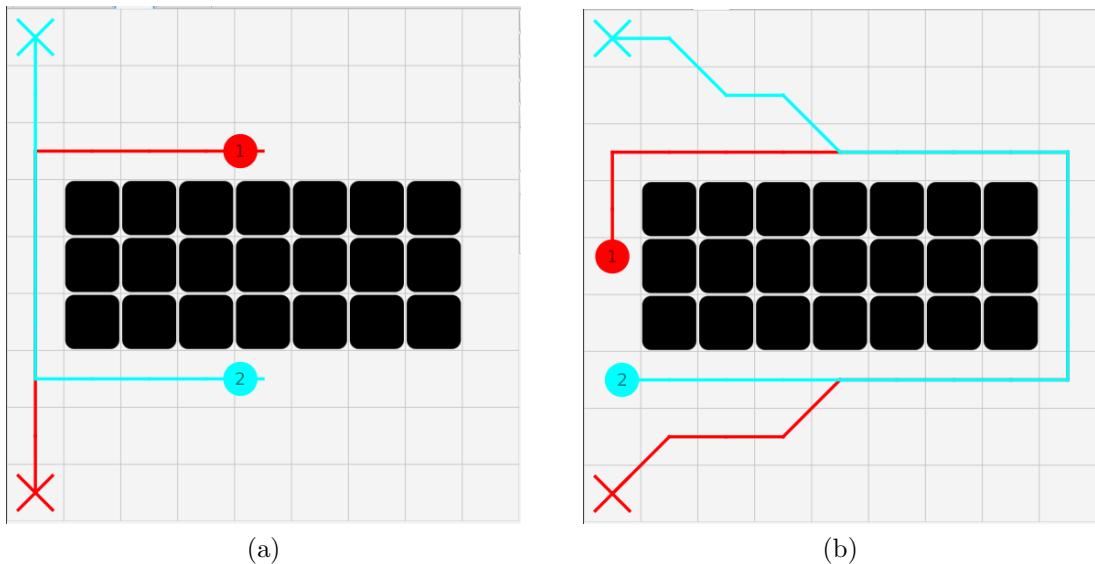
Zasada działania LRA* mocno opiera się na standardowym algorytmie A*. Usprawnieniem jest wykonywanie korekcji tras w przypadku lokalnie wykrytych kolizji.

Planowanie trajektorii odbywa się dla każdego agenta niezależnie, stosując algorytm A*. Przy wyznaczaniu najkrótszej drogi uwzględniane są (jako zajęte pola) zarówno wszystkie przeszkody statyczne, jak i aktualne pozycje pozostałych robotów. Wyznaczona ścieżka dzielona jest na pojedyncze akcje agenta (ruchy robota), które zostają zakolejkowane na liście akcji do wykonania przez robota. Jeśli droga do celu nie mogła zostać wyznaczona, próba ta zostaje powtórzona w następnym kroku.

W każdym kroku symulacji agenci poruszają się wzdłuż wyznaczonych tras. Co prawda w kolejnych krokach ścieżki te mogą być już nieaktualne, jednak agenci wciąż nimi podążają, aż do osiągnięcia punktu docelowego lub wykrycia kolizji. Wykrycie kolizji w tym przypadku nie oznacza odnotowania faktycznego zderzenia (przebywania więcej niż jednego robota na tym samym polu), lecz detekcję wystąpienia takiej niepożądanej sytuacji w następnym kroku symulacji.

Detekcja potencjalnej kolizji sprowadza się do przeanalizowania dla każdego robota jego zaplanowanego położenia z następnego kroku. Jeśli robot nie ma zaplanowanej żadnej ścieżki, oznacza to, że jego położenie w następnym kroku będzie takie samo, jak w obecnym. Uznaje się, że kolizja może wystąpić w dwóch przypadkach:

- w przypadku, gdy zaplanowane położenie robota w następnym kroku jest takie samo, jak



Rysunek 4.4: Przykład układu z powtarzającym się cyklem akcji planowanych przez metodę LRA*: (a) Dwa roboty wyznaczają niezależnie drogi do swoich celów. (b) Chcąc uniknąć zderzenia w wąskim przejściu po lewej stronie, roboty wyznaczają trajektorie przechodzące przez alternatywną ścieżkę po prawej stronie, gdzie ponownie dojdzie do przecięcia się trajektorii.

aktualne położenie innego robota;

- w przypadku, gdy zaplanowane położenie robota w następnym kroku jest takie samo, jak zaplanowane położenie innego robota w następnym kroku.

Sprawdzenie obu tych przypadków jednocześnie jest konieczne, aby wykrywać także zderzenia czołowe robotów zmierzających w przeciwnych kierunkach.

Skutkiem tak wykrytej potencjalnej kolizji jest wykonanie ponownego planowania (tylko dla jednego robota lub dla wielu) trajektorii. Uwzględnienie aktualnego położenia sąsiadującego robota zapobiega zderzeniu się z nim, gdyż pole, które on zajmuje jest już podczas ponownego planowania rozpatrywane jako nieprzejezdne.

Przy takim podejściu priorytety robotów nie mają znaczenia, zaś samo planowanie może odbywać się dla agentów równolegle. W celu poprawy wydajności technikę tą można połączyć z algorytmem D* Lite, D* Extra Lite lub RRA*.

Łatwo zauważyc, że metoda ta nie zapobiega tworzeniu się cykli planowanych akcji - powtarzających się w nieskończoność sekwencji tych samych ruchów, nie doprowadzają agentów do celów (por. rys. 4.4).



Rysunek 4.5: Przykład symulacji ruchu robotów metodą LRA* na dużej mapie z dużą liczbą robotów

4.4 Implementacja algorytmu WHCA*

Implementacja algorytmu *Windowed Hierarchical Cooperative A** oparta została na podstawach teoretycznych opisanych w rozdziałach 3.3, 3.4 oraz 3.5, dla których w znacznym stopniu źródłem był artykuł autorstwa Davida Silvera [11]. Wspomniana praca nie opisuje jednak szczegółów realizacyjnych algorytmu i należało opracować wiele własnych podejść do zaistniałych problemów, dlatego implementacja algorytmu WHCA* w aplikacji jest efektem własnej pracy.

Metoda WHCA* stanowi rozszerzenie A*, dlatego zostaną tu opisane zmiany wprowadzone w stosunku do bazowego algorytmu A*.

W rozdziale tym przedstawiono wariant metody WHCA* bez dynamicznego przydzielu priorytetów. Układ priorytetów robotów, a tym samym kolejność wyznaczania tras jest w tym przypadku losowa. Wariant ten będziemy nazywać metodą **WHCA*1** – w odróżnieniu od innych, przedstawionych w dalszej części pracy (por. 4.5).

4.4.1 Tablica rezerwacji

Dla węzłów na przestrzennej, dwuwymiarowej mapie dodano kolejny wymiar – współrzędną czasu, będącą numerem kroku trajektorii robota. Stan zajętości pól na mapie w danym kroku

czasowym zapisywany jest w tablicy rezerwacji. Tablica rezerwacji ma następujące rozmiary: szerokość mapy \times wysokość mapy \times długość okna czasowego. Rozmiar okna czasowego w podstawowym wariantie WHCA*1 przyjęto jako wielkość stałą, równą całkowitej liczbie agentów na mapie zwiększonej o 1.

Na początku w tablicy rezerwacji wpisywane są położenia przeszkód jako pola zajęte w każdym kroku czasowym. Następnie dla każdego z robotów w kolejności ich priorytetów wyznaczana jest ścieżka do określonego celu.

4.4.2 Możliwe akcje

W każdym kroku symulacji robot musi wybrać jedną spośród możliwych do wykonania akcji. Są to:

- ruch o jedno pole poziomo (wzdłuż długości mapy),
- ruch o jedno pole pionowo (wzdłuż wysokości mapy),
- ruch o jedno pole na ukos,
- pozostanie na tym samym polu.

Odpowiada to odpowiednim przejściom między sąsiednimi węzłami w grafie. Z tego powodu dla węzła o współrzędnych (x, y, t) potencjalnymi sąsiadami (możliwymi przejściami do innego stanu) są węzły:

Tabela 4.1: Możliwe przejścia robota do sąsiednich węzłów z węzła (x, y, t)

$(x - 1, y - 1, t + 1)$	$(x, y - 1, t + 1)$	$(x + 1, y - 1, t + 1)$
$(x - 1, y, t + 1)$	$(x, y, t + 1)$	$(x + 1, y, t + 1)$
$(x - 1, y + 1, t + 1)$	$(x, y + 1, t + 1)$	$(x + 1, y + 1, t + 1)$

Warto zauważyć, że każdy z sąsiadów ma krok czasowy zwiększyony o 1 od węzła aktualnego.

Każdy taki potencjalny sąsiad zostaje zweryfikowany pod kątem poprawności wykonania ruchu oraz zajętości pola w tablicy rezerwacji.

4.4.3 Funkcja kosztu

W ogólnym przypadku koszt wykonania ruchu jest równy reczwyistej przebytej odległości (odległości euklidesowej).

Do powyższej reguły wprowadzono pewne odstępstwo, które eliminuje efekt "opóźnionego" docierania do celu przez agentów. Koszt akcji pozostania na tym samym polu otrzymał wartość

równą $1/maxF$, gdzie $maxF = w \cdot h$ oznacza zakładaną maksymalną wartość funkcji będącej sumą kosztu i heurystyki. Nie dotyczy to sytuacji, w których robot wybiera akcję pozostania na tym samym polu, znajdującej się w polu docelowym – wtedy koszt takiej akcji wynosi 0. Wspomniane zwiększenie kosztu pozostania w miejscu o niewielką wartość "zachęca" do szybszego dotarcia do celu. Modyfikacja funkcji kosztu o niewielką wartość nie koliduje z wartościami wyznaczonymi na podstawie przebytej odległości. Gdyby funkcja kosztu zależna była jedynie od rzeczywistej przebytej drogi, to agenci mogliby zatrzymywać się niepotrzebnie przed dotarciem do celu, gdyż nie wpływałoby to w żaden sposób na koszt ich trajektorii. Zależałoby to tylko od czynników losowych z powodu równego traktowania takich sytuacji. Takie zachowanie było obserwowane przed wprowadzeniem wspomnianej modyfikacji funkcji kosztu. Roboty zatrzymywały się na kilka kroków przed osiągnięciem celu, mimo iż nic nie stało na przeszkodzie, aby dotrzeć do celu wcześniej. Było to spowodowane tym, że rozwiązanie spełniało swoje założenie - nadal miało minimalny koszt i mieściło się w wyznaczonym oknie czasowym. Zatem "zniechęcanie" do postoju poprzez sztuczne zwiększenie kosztu przejścia między węzłami okazało się skutecznie zapobiegać takim, niepożądany zachowaniom robotów.

4.4.4 Funkcja heurystyczna

Funkcja heurystyczna, która ma na celu oszacować długość pozostałąj drogi do celu, wykorzystuje przestrzenny algorytm A*. Funkcja ta zwraca dokładne oszacowania odległości do celu, ignorując potencjalne interakcje z innymi agentami. Jej niedokładność będzie wynikać jedynie z trudności związanych z interakcją z innymi agentami. Wynikiem jest długość wyznaczonej trasy z obecnego punktu do celu. Głębokość tego przeszukiwania nie jest ograniczona oknem czasowym. Aby przyspieszyć wykonywanie algorytmu i zapobiec zbędnemu powtarzaniu obliczeń, wynik zapisywany jest w pamięci podręcznej. Jest to mapa (w sensie kolekcji) o dwóch kluczach całkowitoliczbowych (współrzędnych x i y) i wartością będącą zapamiętaną długością trasy. W przypadku, gdy przestrzenny algorytm A* nie potrafi znaleźć rozwiązania (brak istnienia drogi do celu) jako wartość heurystyki algorytmu WHCA* zwracana jest maksymalna wartość $maxF$.

4.4.5 Wybór najbardziej obiecującego rozwiązania

Przeszukiwanie węzłów jest ograniczone wielkością okna czasowego. Jeśli po przejściu wszystkich węzłów nie znaleziono węzła będącego punktem docelowym, to po zakończeniu głównej pętli algorytmu należy wybrać rozwiązanie spośród listy odwiedzonych węzłów. Należy zaznaczyć, że w takiej sytuacji algorytm nie zwraca optymalnej ścieżki i należy wybrać najbardziej obiecujące rozwiązanie. W zaproponowanej implementacji algorytmu WHCA* najbardziej obiecujące

rozwiązań wybierane jest z listy *zamkniętych* (węzłów odwiedzonych i przeanalizowanych):

1. Pozostawiane są tylko te węzły, dla których wartość heurystyki jest mniejsza od $\max F$ (istnieje droga do celu)
2. Zwracany jest węzeł spełniający kryterium (jeśli nadal pozostaje wielu kandydatów, rozstrzygają kolejne kryteria):
 - (a) Wybranie węzła o najmniejszej wartości heurystyki (najbliżej celu).
 - (b) Wybranie węzła o najmniejszej wartości funkcji kosztu (najkrótsza droga).
 - (c) Wybranie węzła o najmniejszej wartości współrzędnej czasu (najszybsza droga).

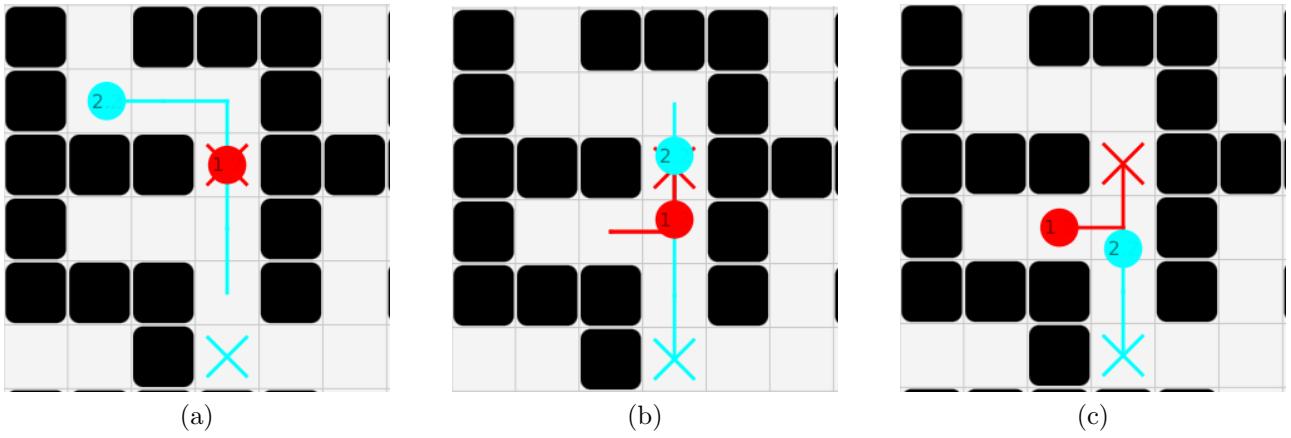
Dla wybranego w ten sposób węzła tworzona jest ścieżka, która jest budowana poprzez rekurencyjne przechodzenie po kolejnych rodzinach przypisanych do węzłów. Zatem wynikiem algorytmu planowania może być tylko częściowa ścieżka (zależna od długości okna czasowego), którą robot będzie podążał w dalszych krokach symulacji. Po wyznaczeniu ścieżki do kolejki ruchów robota zostają dodane zaplanowane akcje oraz zaznaczana jest obecność robota w odpowiednich polach i czasie w tablicy rezerwacji. Jeśli wszystkie zaplanowane ruchy zostały wykonane (pusta kolejka akcji), to dokonuje się kolejnego planowania tras. Tym razem okno czasowe jest już przesunięte o odpowiednią liczbę wykonanych kroków symulacji.

4.4.6 Uzyskane wyniki

Obserwacja zachowania robotów symulowanego metodą WHCA*1 pozwala stwierdzić, że roboty wykazują bardziej "inteligentne" zachowanie w porównaniu np. do metody LRA*. W pewnych sytuacjach potrafią kooperować ze sobą, schodzić sobie z drogi, nawet, gdy już dotarły do swojego celu (por. rys. 4.6). Warto dodać, że w sytuacji przedstawionej na rysunku 4.6 metoda WHCA*1 nie znalazła rozwiązań, gdyby roboty miały odwrotnie przydzielone priorytety.

Obszerne testy skuteczności oraz innych wskaźników zaprojektowanej metody WHCA*1 zostały opisane dokładniej w dalszym rozdziale 6.

Wadą i ograniczeniem metody jest niezmieniający się przydział priorytetów robotów oraz stała szerokość okna czasowego. W kolejnej części pokażemy, że dopiero wprowadzenie dynamicznego przydzielania priorytetów oraz skalowania okna czasowego, pozwoliło jeszcze skuteczniej rozwiązywać skomplikowane problemy zakleszczenia robotów.



Rysunek 4.6: Przykładowa sytuacja "przepuszczania się" robotów uzyskana metodą WHCA*1:
(a) Wyznaczona trasa przez robota 2 koliduje z aktualnym położeniem robota 1, który dotarł już do celu. (b) Robot 1 schodzi z drogi robotowi 2, ukrywając się we "wnęce". (c) Robot 2 może bezkolizyjnie dotrzeć do celu. Następnie robot 1 może powrócić do celu.

4.5 Dynamiczny przydział priorytetów

Obok samego algorytmu WHCA* zrealizowano własną metodę dynamicznego przydziału priorytetów oraz skalowania okna czasowego, która to przyczynia się do zwiększenia skuteczności planowania ruchu robotów. Stanowi ona niejako rozwinięcie metody WHCA* o dodatkowe procedury. Dla rozróżnienia poszczególnych wariantów metody WHCA* w dalszej części pracy będziemy posługiwać się skrótowymi nazwami:

- **WHCA*1** - *Windowed Hierarchical Cooperative A** bez dynamicznego przydzielania priorytetów, ze stałym oknem czasowym,
- **WHCA*2** - *Windowed Hierarchical Cooperative A** z dynamicznym przydziałem priorytetów, ze stałym oknem czasowym,
- **WHCA*3** - *Windowed Hierarchical Cooperative A** z dynamicznym przydziałem priorytetów oraz skalowaniem okna czasowego.

Układ priorytetów w metodzie WHCA* ma znaczący wpływ na wynik planowania tras. Od priorytetów robotów zależy kolejność wyznaczania tras. Jest to na tyle istotne, gdyż podczas wyznaczania tras uwzględniane są tylko roboty o priorytetach wyższych (których planowanie odbyło się wcześniej).

4.5.1 Detekcja kolizji

Podobnie jak w algorytmie LRA*, również w metodzie WHCA* należy wykrywać kolizje (odpowiednio wcześniej). Nawet w przypadku, gdy roboty podążają wzdłuż zaplanowanych ścieżek, wciąż istnieje możliwość wystąpienia kolizji. Taka sytuacja może wystąpić, gdy robot, który planuje drogę wcześniej (ma wyższy priorytet), nie uwzględnia, że następnemu robotowi może nie udać się wyznaczenie trajektorii (z powodu właśnie zaplanowanej trasy). Wykrywanie kolizji odbywa się tak samo, jak w przypadku metody LRA* (por. 4.3). Należy zaznaczyć, że pod pojęciem wykrywania kolizji rozumiemy wcześnie zauważenie kolizji, która wystąpiłaby w kolejnym kroku. Niepożądane jest doprowadzanie do faktycznych kolizji, dlatego interwencja zachodzi odpowiednio wcześniej.

4.5.2 Wariant WHCA*2

Wariant WHCA*2 został wzbogacony o dynamiczny przydział priorytetów agentów. Zapropowane podejście polega na zwiększaniu priorytetów robotów w przypadku niepowodzenia w znalezieniu trasy. Opiera się to na następujących krokach:

1. Początkowo roboty mają nadane priorytety losowo. Otrzymują kolejne wartości od 1 do liczby wszystkich robotów.
2. Rozmiar okna czasowego jest zawsze równy całkowitej liczbie agentów zwiększonej o 1.
3. Planowanie tras dla robotów wykonywane jest w przypadku detekcji kolizji w poprzednim kroku symulacji, lub gdy robot wykonał już wszystkie akcje z jego indywidualnej kolejki akcji. Lista robotów zostaje posortowana malejąco według priorytetów przed wykonaniem planowania tras. Wyższa wartość priorytetu oznacza pierwszeństwo podczas planowania.
4. Następnie wykonywane jest planowanie tras zgodnie z aktualnym układem kolejności robotów (jak w wariantie WHCA*1). Wyznaczone ścieżki zaznaczane są kolejno w tablicy rezerwacji.
5. Jeśli dla któregoś robota nie została znaleziona bezkolizyjna ścieżka, to następuje zwiększenie jego priorytetu o wartość 1. Taki awans priorytetów może nastąpić dla wielu robotów w jednym kroku symulacji.
6. Dla wszystkich robotów dokonywana jest weryfikacja wystąpienia kolizji. W przypadku jej wykrycia, kolejka ruchów obydwu (lub więcej) robotów zostaje opróżniona.

7. W następnych krokach symulacji zostanie podjęta próba ponownego poszukiwania tras dla robotów, u których wystąpiło niepowodzenie planowania lub została wykryta kolizja. Tym razem nastąpi to z nowym układem priorytetów.

Rozmiar okna czasowego jest stały i jest równy całkowitej liczbie agentów na mapie zwiększonej o 1.

4.5.3 Wariant WHCA*3

Wariant WHCA*3 stanowi rozszerzenie WHCA*2 o procedurę skalowania okna czasowego. Rozmiar okna czasowego może zmieniać się w trakcie trwania symulacji.

Poniżej przedstawiono kroki wariantu WHCA*3. Modyfikacje w stosunku do wariantu WHCA*2 zostały oznaczone jako pogrubione. Wprowadzają one dodatkowe powiększanie okna czasowego do procedury dynamicznego przydziału priorytetów:

1. Początkowo roboty mają nadane priorytety losowo. Otrzymują kolejne wartości od 1 do liczby wszystkich robotów.
2. **Rozmiar okna czasowego jest początkowo równy całkowitej liczbie agentów zwiększonej o 1.**
3. Planowanie tras dla robotów wykonywane jest w przypadku detekcji kolizji w poprzednim kroku symulacji, lub gdy robot wykonał już wszystkie akcje z jego indywidualnej kolejki akcji. Lista robotów zostaje posortowana malejąco według priorytetów przed wykonaniem planowania tras. Wyższa wartość priorytetu oznacza pierwszeństwo podczas planowania.
4. Następnie wykonywane jest planowanie tras zgodnie z aktualnym układem kolejności robotów (jak w wariantie WHCA*1). Wyznaczone ścieżki zaznaczane są kolejno w tablicy rezerwacji.
5. Jeśli dla któregoś robota nie została znaleziona bezkolizyjna ścieżka, to następuje zwiększenie jego priorytetu o wartość 1. Taki awans priorytetów może nastąpić dla wielu robotów w jednym kroku symulacji.
 - (a) **Jeśli nowa wartość priorytetu robota przekracza aktualną wartość rozmiaru okna czasowego, to okno czasowe zostaje zwiększone do wartości równej maksymalnemu priorytetowi robota.**
6. Dla wszystkich robotów dokonywana jest weryfikacja wystąpienia kolizji. W przypadku jej wykrycia, kolejka ruchów obydwu (lub więcej) robotów zostaje opróżniona.

7. W następnych krokach symulacji zostanie podjęta próba ponownego poszukiwania tras dla robotów, u których wystąpiło niepowodzenie planowania lub została wykryta kolizja. Tym razem nastąpi to z nowym układem priorytetów.

Rozszerzanie okna czasowego pozwala na poszukiwanie coraz bardziej skomplikowanych rozwiązań, gdy wciąż nie udaje się znaleźć rozwiązania. Jednocześnie nie przeznaczamy większej mocy obliczeniowej już na początku, gdy prawdopodobnie odbyłoby się planowanie w niepotrzebnie dużej głębi przeszukiwania.

Wykonane testy potwierdziły wzrost skuteczności w wyznaczaniu tras dzięki wprowadzeniu metody zarówno dynamicznego przydziału priorytetów jak i rozszerzania okna czasowego dla algorytmu WHCA* (por. 6.3).

4.6 Ograniczenia metod

W aplikacji zostały wprowadzone pewne uproszczenia, które m.in. przyspieszają i ułatwiają proces obliczeniowy planowania trajektorii dla robotów.

1. Założono, że ruch ukośny robota o jedno pole (po przekątnej) trwa tyle samo, co ruch poziomy lub pionowy. Wprowadzono takie przybliżenie ze względu na możliwość ujednolicenia jednostki wymiaru czasu w tablicy rezerwacji pól przez agentów.
2. Nie uwzględniono czasu obrotu robota podczas zmiany kierunku jazdy. Założono, że czas ten jest zerowy, gdyż celem zaprojektowanego algorytmu było skupienie się na rozwiązaniu innego zagadnienia - problemu zakleszczeń w wąskich gardłach.

Rozdział 5

Oprogramowanie symulacyjne

Na potrzeby pracy zostało stworzone oprogramowanie symulacyjne, które posłużyło do przeprowadzenia testów skuteczności algorytmów planowania tras oraz wizualizacji działania metod. W tym rozdziale opisano techniczne rozwiązania wykorzystane podczas tworzenia oprogramowania. W aplikacji zostały zaimplementowane algorytmy planowania tras opisane w rozdziale 4. Prezentacja ich działania odbywa się poprzez wizualizację ruchu robotów mobilnych w czasie rzeczywistym.

5.1 Funkcjonalności aplikacji

Aplikacja umożliwia dowolne definiowanie przez użytkownika środowiska, w którym poruszają się roboty. Obejmuje to:

- wybór rozmiaru mapy - dowolną wysokość oraz szerokość. Mapa nie musi być kwadratowa.
- możliwość wygenerowania mapy za pomocą generatora labiryntów (por. 4.1) lub manualnego umieszczania przeszkód na mapie za pomocą myszki,
- wybór liczby robotów i dokonanie ich automatycznego rozmieszczenia na mapie (w losowych polach z pominięciem pól zajętych). Użytkownik ma także możliwość manualnego dodawania i usuwania robotów.

Aplikacja przeprowadza symulację ruchu robotów w czasie rzeczywistym. W oprogramowaniu zostały zaimplementowane trzy algorytmy planowania ruchu robotów. Są to:

- Metoda pól potencjałowych (por. 2.3)
- Local-Repair A* (por. 4.3)

- WHCA*3 - Windowed Hierarchical Cooperative A* z dynamicznym przydziałem priorytetów oraz skalowaniem okna czasowego (por. 4.4, 4.5)

Wizualizacja każdego z tych algorytmów dostępna jest na osobnej zakładce w aplikacji.

5.2 Graficzny interfejs użytkownika

Graficzny interfejs użytkownika stanowi desktopowa aplikacja okienkowa, której głównym elementem jest panel zakładek. Każda z zakładek reprezentuje wizualizację osobnego algorytmu planowania ruchu robotów.

Z myślą o spopularyzowaniu i rozpowszechnieniu opracowanych algorytmów, elementy interfejsu użytkownika (takie, jak etykiety lub przyciski) posiadają tekst w języku angielskim.

Pod każdą z zakładek aplikacji układ wizualny jest podobny. Poniżej opisano graficzny interfejs użytkownika wspólny dla wszystkich zakładek (por. rys. 5.3).

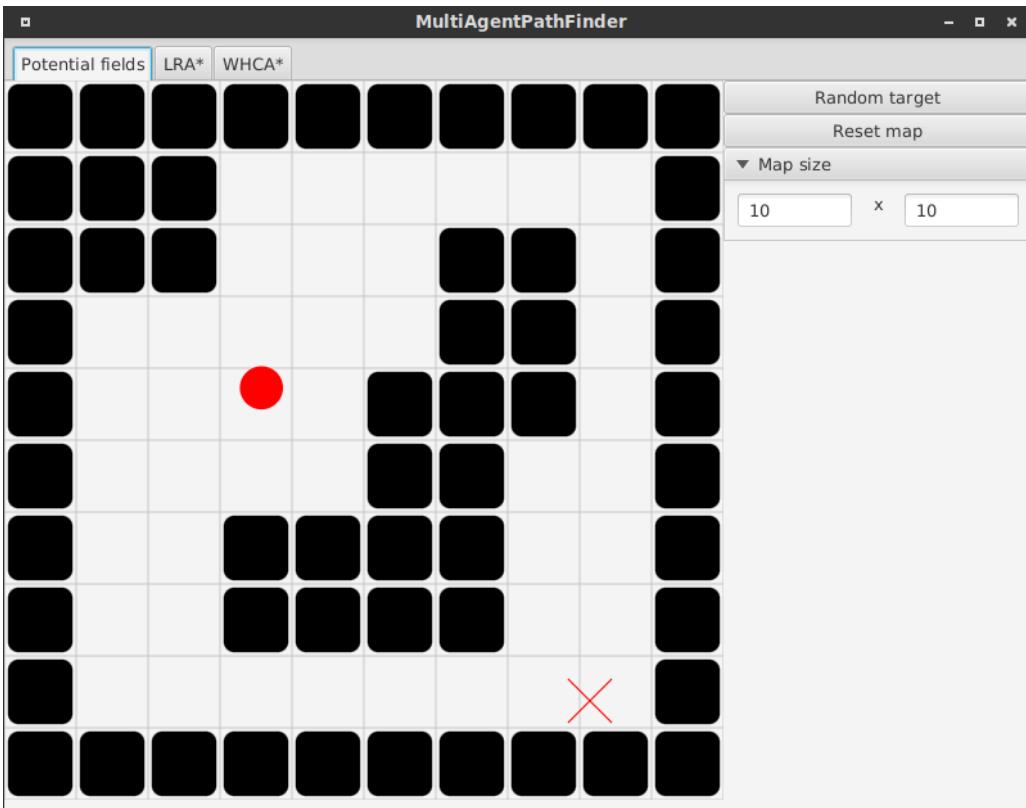
Po prawej stronie znajduje się panel przycisków akcji oraz panel rozwijanych właściwości z konfiguracją parametrów mapy oraz symulacji. Natomiast po lewej stronie wyświetlany jest obecny stan mapy i położenie robotów mobilnych. Mapa wyświetlana jest z zaznaczeniem linii siatki pól obrazujących liczbę pól na mapie. Przeszkody wyświetlane są jako czarne kwadraty, zaś roboty jako kolorowe wypełnione koła. Kliknięcie prawym przyciskiem myszy (również z możliwością ciągłego przytrzymania) powoduje wstawienie lub usunięcie przeszkodej na mapie w odpowiednich polach. Punkty docelowe, do których podążają roboty wyświetlane są jako krzyżyki w kolorze takim samym, jaki został przypisany do robota. Liczba robotów nie jest ograniczona przez aplikację. Aby odróżnić roboty między sobą, każdy robot otrzymuje inny kolor wynikający z równomiernego podziału na liczbę robotów zakresu barwy (ang. *hue*) z palety HSV.

Okno aplikacji jest skalowalne i w pełni responsywne. Po zmianie rozmiaru okna przez użytkownika rozmiar mapy dopasowuje się do maksymalnego obszaru, jaki może zająć (z zachowaniem proporcji wymiarów mapy).

Symulacja ruchu robotów rozpoczyna się, gdy tylko zostanie wyznaczony punkt docelowy dla robota. Dzięki temu, że wykonywanie obliczeń planowania tras zostało przeniesione do osobnych wątków, uzyskano płynność animacji ruchu robotów mobilnych. Uniknięto również problemu braku odpowiedzi okna interfejsu użytkownika podczas planowania trajektorii.

5.2.1 Metoda pól potencjałowych

Na pierwszej zakładce "Potential fields" w oknie aplikacji przedstawiona jest wizualizacja metody pól potencjałowych.



Rysunek 5.1: Zrzut ekranu aplikacji w trakcie wizualizacji metody pól potencjałowych.

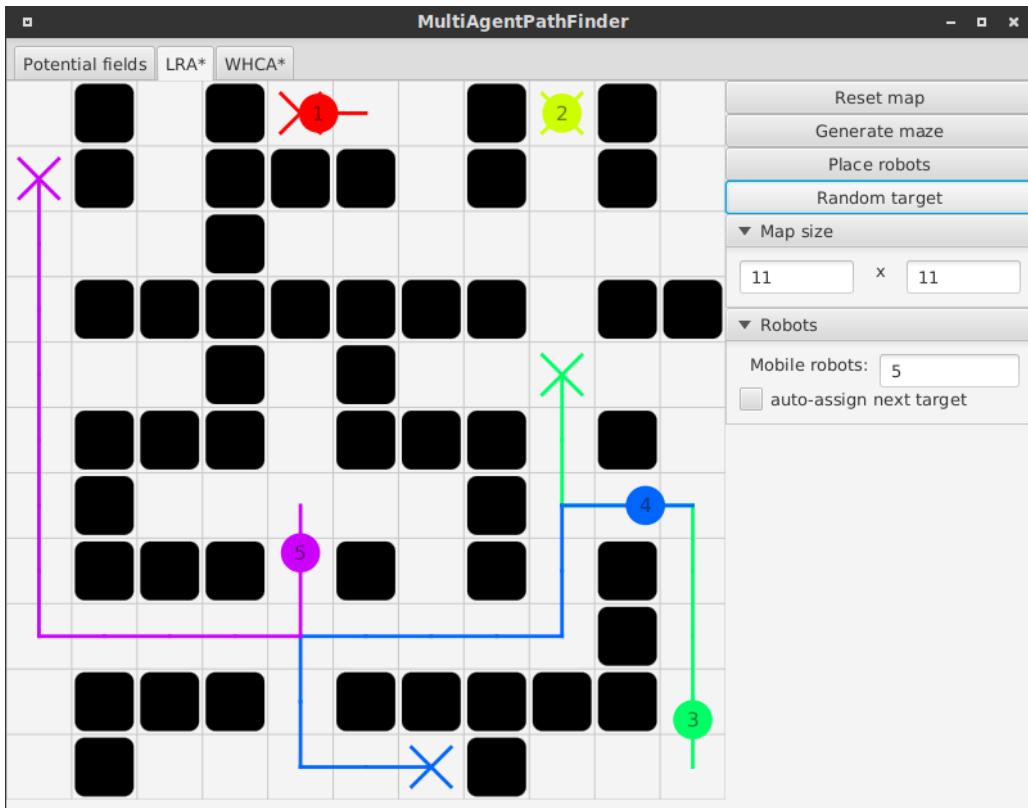
Na panelu konfiguracji parametrów, użytkownik może wybrać dowolny rozmiar mapy, podając szerokość i wysokość wyrażone w liczbie pól. Po naciśnięciu przycisku "Reset map" tworzona jest nowa mapa o zadanych rozmiarach, natomiast pozycja początkowa robota zostaje wylosowana. Naciśnięcie przycisku "Random target" powoduje wyznaczenie losowego punktu na mapie jako celu dla robota i rozpoczęcie podążania za nim.

Klikając lewym przyciskiem myszy na mapie, użytkownik może manualnie wskazać punkt docelowy dla robota. Planowanie i symulacja ruchu robota odbywa się w trybie ciągłym. Robot nie jest ograniczony zdyskretyzowaną siatką pól na mapie, jego przestrzeń poruszania się jest ciągła.

5.2.2 Local-Repair A*

Pod kolejną zakładką "LRA*" w oknie aplikacji dostępna jest wizualizacja metody algorytmu bazującego na A* z lokalną detekcją i rozwiązywaniem kolizji.

Na panelu konfiguracji parametrów w sekcji "Map size", użytkownik może wybrać dowolny rozmiar mapy, podając szerokość i wysokość wyrażone w liczbie pól. Po naciśnięciu przycisku "Reset map" tworzona jest nowa, pusta mapa o zadanych rozmiarach. W sekcji "Robots" użytkownik wybiera liczbę robotów (do automatycznego rozmieszczenia) oraz ma możliwość



Rysunek 5.2: Zrzut ekranu aplikacji w trakcie wizualizacji metody Local-Repair A*.

zaznaczenia opcji "auto-assign next target", co skutkuje automatycznym wyznaczaniem kolejnego punktu docelowego, dla robota, który dotarł do poprzedniego celu. Przycisk "Generate maze" pozwala na wygenerowanie labiryntu przy użyciu generatora map (por. 4.1). Przycisk "Place robots" usuwa wszystkie roboty z mapy i umieszcza na niej wybraną przez użytkownika liczbę robotów w losowych miejscach na mapie (z pominięciem pól zajętych przez przeszkody oraz inne roboty). Przycisk "Random target" losuje punkty docelowe dla wszystkich robotów. Każdy z agentów otrzymuje inny punkt docelowy (nie będący przeszkodą), do którego zmierza. Nadanie punktów docelowych powoduje rozpoczęcie planowania trajektorii i symulację ruchu agentów.

Klikając lewym przyciskiem myszy na mapie, użytkownik może utworzyć nowego robota. Nowemu agentowi zostaje przydzielony punkt docelowy w miejscu, w którym lewy przycisk myszy został zwolniony. Dodatkowo pokazywane są zaplanowane ścieżki dla każdego robota. Wyświetlane są jako linie łamane w kolorze takim samym, jaki odpowiada robotowi. Nad robotem, w jego aktualnym położeniu wyświetlany jest jego numer (identyfikator).

5.2.3 Windowed Hierarchical Cooperative A*

Pod ostatnią zakładką "WHCA*" w oknie aplikacji dostępna jest wizualizacja metody kooperacyjnego planowania tras dla wielu robotów z wykorzystaniem wariantu metody WHCA*3 z dynamicznym przydziałem priorytetów oraz skalowaniem okna czasowego (por. 4.5).

Interfejs użytkownika jest praktycznie taki sam, jak w przypadku opisanej metody LRA* (por. 5.2.2). Różni się obecnością dodatkowej sekcji "WHCA*" na panelu konfiguracji z polem "Time window", które pozwala na zmianę początkowej wielkości okna czasowego dla algorytmu WHCA*. W wyniku dynamicznego przydzielania priorytetów wielkość ta może zostać zwiększała automatycznie podczas symulacji. Dodatkowy przycisk "Restore positions" pozwala na cofnięcie stanu robotów do momentu, tuż przed rozpoczęciem symulacji (zaraz po przydzieleniu punktów docelowych). Pozwala to na ponowną obserwację przebiegu symulacji dzięki przywróceniu położenia i stanu agentów.

Nad robotem, w jego aktualnym położeniu wyświetlany jest jego numer (identyfikator) oraz priorytet (oddzielony kropką). Priorytet może być zmienny w trakcie symulacji (w przeciwieństwie do identyfikatora). Początkowo robot zawsze ma priorytet równy identyfikatorowi. Większa wartość priorytetu względem pozostałych oznacza pierwszeństwo uwzględniane podczas planowania tras.

5.3 Wykorzystane technologie

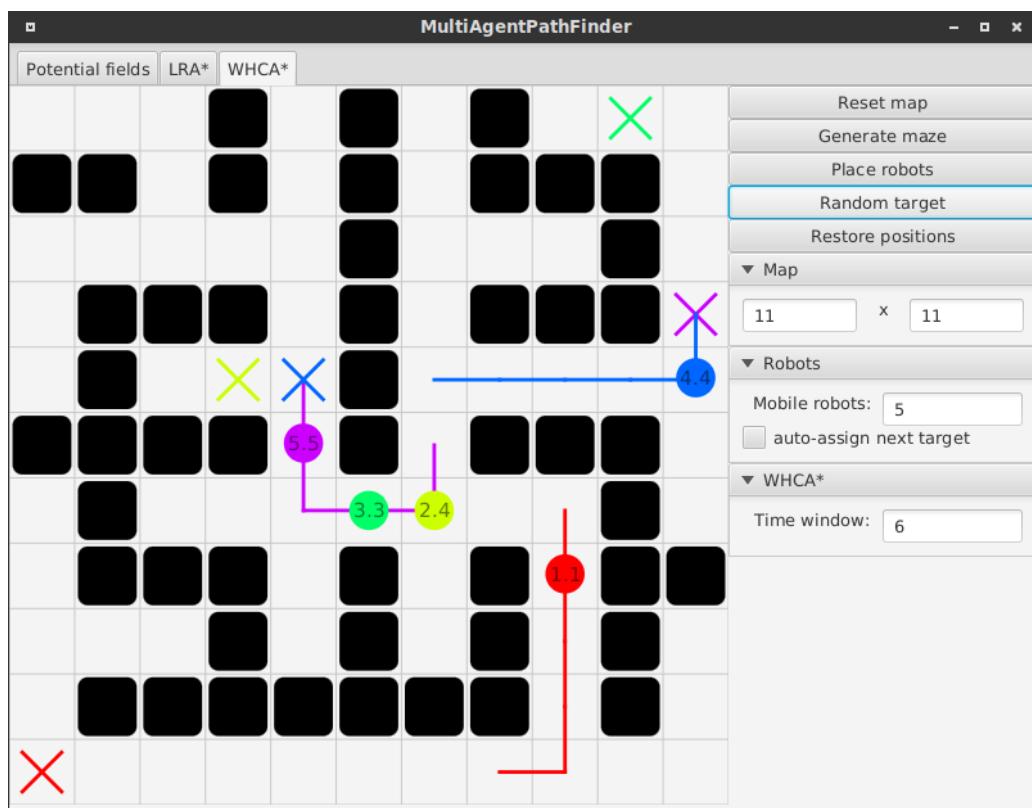
Do stworzenia aplikacji wykorzystano wiele technologii, narzędzi deweloperskich oraz technik opisanych w poniższych podrozdziałach.

Aplikacja była rozwijana i testowana na systemach operacyjnych z jądrem Linux (Arch Linux oraz Debian 9), jednak wszystkie zastosowane narzędzia oraz technologie są wieloplatformowe i z powodzeniem mogą zostać uruchomione na innych systemach operacyjnych (np. macOS lub Windows).

5.3.1 Java 8

Aplikacja w całości została napisana w języku Java. Java jest językiem programowania ogólnego przeznaczenia, zorientowanym obiektowo. Posiada obsługę wyjątków oraz naturalne wsparcie dla wielowątkowości, pozwala na szybkie tworzenie wysokopoziomowych programów. Aplikacje napisane w języku Java kompilowane są do kodu bajtowego, który uruchamiany jest przez wirtualną maszynę Javy (JVM), niezależnie od architektury urządzenia.

Dzięki wieloplatformowości stworzony program może być uruchamiany na każdym systemie operacyjnym z wirtualną maszyną Javy.



Rysunek 5.3: Zrzut ekranu aplikacji w trakcie wizualizacji metody Windowed Hierarchical Cooperative A*.

W projekcie aplikacji wykorzystano język Java w wersji 8. Pozwoliło to na użycie w projekcie takich elementów języka, jak: wyrażenia lambda i interfejsy funkcyjne (skracające zapis i zwiększające czytelność kodu) oraz strumienie (stream API) - do szybkiego i przejrzystego przekształcania i filtracji zbiorów danych.

5.3.2 JavaFX

JavaFX jest platformą do tworzenia aplikacji desktopowych (okienkowych) pisanych w języku Java. Od wersji 8 JavaFX została włączona do platformy Java Standard Edition. Jest to nowsze, obecnie zalecane przez firmę *Oracle* rozwiązanie do tworzenia aplikacji okienkowych. Niezalecane jest natomiast korzystanie z bibliotek *AWT* lub *Swing* [26].

Do zbudowania widoków aplikacji wykorzystano specjalny format plików FXML, w którym to JavaFX przechowuje informację o właściwościach komponentów interfejsu użytkownika oraz o ich wzajemnych relacjach i położeniu na ekranie.

5.3.3 Spring

Spring Framework

Spring jest frameworkiem, który umożliwia w aplikacjach Javy zastosowanie wzorca architektonicznego odwrócenia sterowania (IoC - ang. *Inversion of Control*), a w szczególności wstrzykiwania zależności (ang. *Dependency Injection*). Pozwala to uniknąć występowania bezpośrednich zależności pomiędzy komponentami oraz umożliwia automatyczne dostarczanie i zarządzanie cyklem życia komponentów aplikacji.

W zaprojektowanej aplikacji Spring jest wykorzystywany m.in. do automatycznego dostarczania współdzielonych danych o parametrach symulacji oraz do zarządzania cyklem życia klas prezenterów i widoków z biblioteki JavaFX.

Spring Boot

Spring Boot jest rozwiązaniem przyspieszającym proces konfiguracji, tworzenia oraz uruchamiania aplikacji opartych na Spring Framework. Jest to zestaw wstępnie skonfigurowanych komponentów, dzięki którym jeszcze łatwiejsze staje się dołączenie nowych bibliotek zewnętrznych do projektu. Celem jest pozbycie się zbędnych konfiguracji w plikach XML a zastąpienie ich domyślnym zestawem konfiguratorów, gdyż większość komponentów w aplikacji zazwyczaj konfigurowana jest w typowy, powtarzalny sposób [20].

Spring Boot dostarcza do aplikacji symulacyjnej wiele zależności do bibliotek (np. logback) oraz dostarcza wsparcie dla konfiguracji systemu budowania Maven.

Spring Boot JavaFx Support

Spring Boot JavaFx Support jest niewielką biblioteką umożliwiającą użycie Spring Boot w jednym projekcie w połączeniu z JavaFX.

5.3.4 jUnit i Test-driven development

jUnit jest frameworkiem do wykonywania testów jednostkowych dla programów napisanych w Javie. Testy jednostkowe weryfikują poprawność działania pojedynczych komponentów aplikacji. Uruchamiane są automatycznie podczas budowania projektu.

W projekcie zastosowano podejście TDD (ang. *Test-driven development*) dla procesu rozwoju oprogramowania. Dotyczy to w szczególności rozwoju logiki silnika planowania tras dla algorytmu A* i WHCA*. Algorytm WHCA* jest na tyle złożony, że zdecydowano się najpierw napisać szczegółowe przypadki testowe, które określały jakie dane wyjściowe (zaprojektowane trajektorie) są oczekiwane przy zadanych danych wejściowych. Dopiero po takim pokryciu testami przystąpiono do implementacji algorytmu. Warunkiem poprawności zaimplementowanego algorytmu było, aby wszystkie testy jednostkowe wykonały się prawidłowo. Na tym podejściu opiera się proces TDD (ang. *Test-driven development*), który jest naturalnie wspierany przez framework jUnit.

Bibliotekę jUnit wykorzystano także do automatycznego wykonania obszernych testów skuteczności algorytmów i wszystkich pozostałych testów opisanych w rozdziale 6. Zastosowanie w tym celu biblioteki jUnit, umożliwia wykonanie fragmentów logiki w innych, niestandardowych trybach pracy, bez jednoczesnej zmiany działania głównej aplikacji.

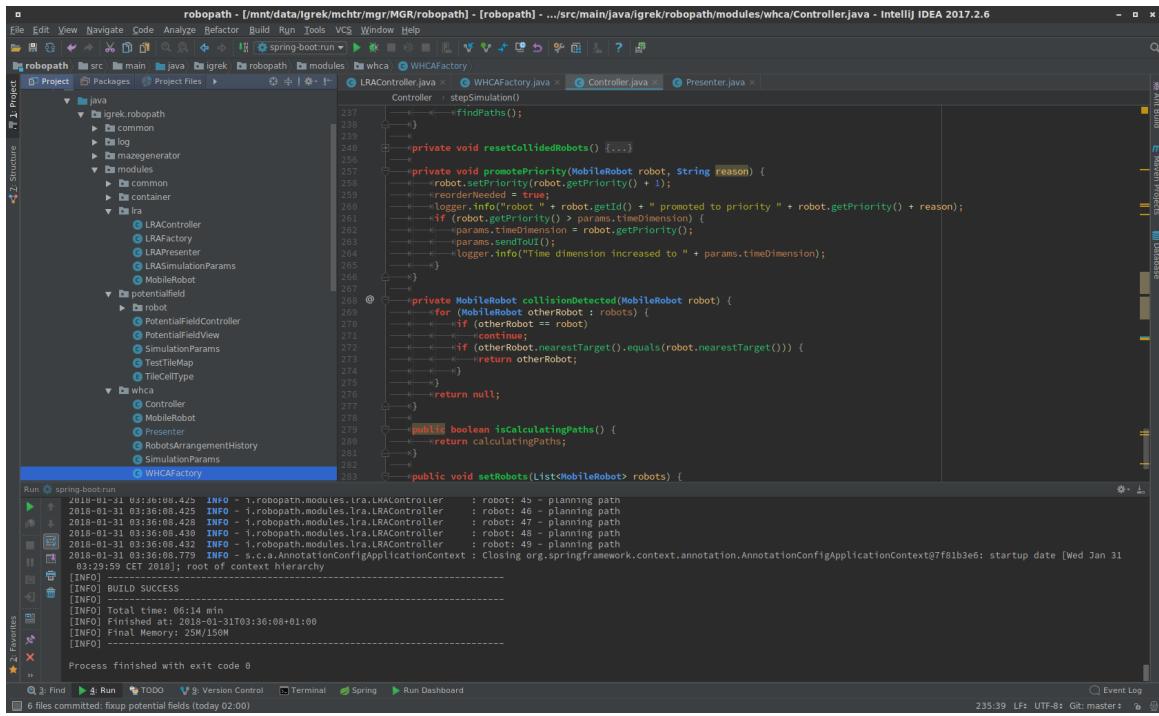
5.3.5 Maven

Apache Maven jest narzędziem do automatyzacji procesu budowania aplikacji napisanych w języku Java. Przy pierwszym wykorzystaniu zadeklarowanych bibliotek Maven automatycznie pobiera biblioteki ze swojego repozytorium i rozwiązuje wszystkie brakujące zależności do nich. Użytkownik zatem nie musi martwić się o brakujące biblioteki i o manualne dołączanie ich do projektu.

Narzędzie to zostało użyte w aplikacji do komplikacji ze źródeł oraz uruchamiania. Konfiguracja procesu budowania dla Maven jest wspomagana przez Spring Boot. Zbudowanie programu z kodów źródłowych i uruchomienie następuje po wykonaniu w systemie polecenia:

```
mvn spring-boot:run
```

Do komplikacji i uruchomienia całej aplikacji wystarczy zatem, aby w systemie operacyjnym było zainstalowane oprogramowanie JDK SE w wersji 8 (lub wyższej) oraz *Apache Maven*.



Rysunek 5.4: Zrzut ekranu środowiska deweloperskiego IntelliJ IDEA Ultimate

Wszystkie brakujące biblioteki powinny zostać pobrane automatycznie z sieci Internet.

5.3.6 IntelliJ IDEA

IntelliJ IDEA jest zintegrowanym środowiskiem deweloperskim przeznaczonym głównie do rozwoju aplikacji w języku Java. Podczas opracowywania oprogramowania korzystano z wersji IntelliJ IDEA Ultimate 2017.2.6, z licencji studenckiej. Zrzut ekranu podczas pracy ze środowiskiem zaprezentowano na rysunku 5.4. Środowisko to zapewnia integrację ze wszystkimi technologiami wymienionymi w tym podrozdziale.

5.3.7 Pozostałe narzędzia i biblioteki

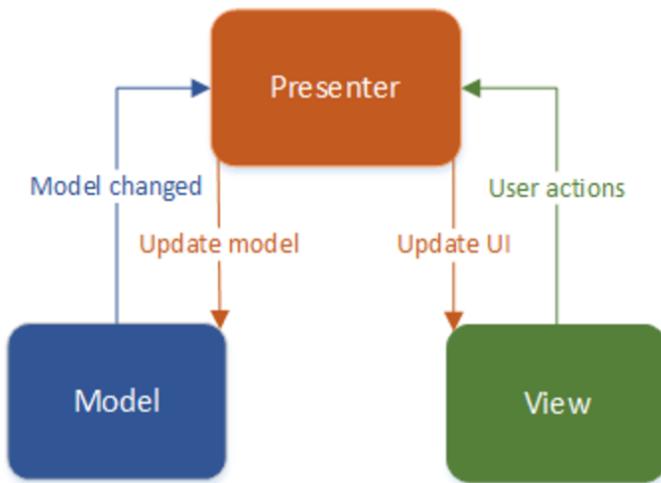
Guava

Guava jest biblioteką rozwijaną przez Google dostarczającą do Javy m.in. nowe typy kolekcji (struktur danych). W rozwijanej aplikacji wykorzystano ją m.in. do przetwarzania łańcuchów tekstowych.

git

Do śledzenia i zapisywania zmian wykorzystano w projekcie system kontroli wersji *git*. Kody źródłowe powstałego programu są ogólnie dostępne w repozytorium git na portalu GitHub [22].

MVP



Rysunek 5.5: Relacja pomiędzy poszczególnymi elementami wzorca architektonicznego Model-View-Presenter. Źródło: [21]

Logback

Do zapisu dziennika zdarzeń oraz błędów zaistniałych w aplikacji została wykorzystana biblioteka *Logback*, która jest domyślnie dostarczana do aplikacji i skonfigurowana dzięki *Spring Boot*.

5.4 Struktura aplikacji

5.4.1 Wzorzec Model-View-Presenter

Bardzo istotnym aspektem projektowanego oprogramowania okazała się być jego architektura. Przed będącym przedmiotem tego rozdziału symulatorem ruchu robotów zostało postawione wymaganie możliwości wykonania symulacji zarówno w trybie graficznej wizualizacji w czasie rzeczywistym, jak i w trybie przeprowadzenia obszernych automatycznych testów algorytmów w celu zebrania potrzebnych danych statystycznych.

Oprogramowanie zostało zorganizowane w architekturę warstwową. Główny szkielet aplikacji zbudowany jest w oparciu o wzorzec architektoniczny MVP (ang. *Model-View-Presenter* - Model-Widok-Prezenter), będący pochodną wzorca MVC (ang. *Model-View-Controller*). Takie podejście zapewnia separację głównej logiki dziedziny programu od warstwy interfejsu użytkownika [21] (por. rys. 5.5).

Wybrano podejście MVP, gdyż (w porównaniu do MVC) oferuje ono łatwiejszą testowalność kodu, możliwość ”odczepiania” i wymieniania poszczególnych warstw (w celach testowania). Zapewnia to także większą separację modelu z widokiem, które nie muszą ”wiedzieć” o sobie, a komunikują się jedynie za pośrednictwem prezentera.

Każda zaimplementowaną metodę symulacji ruchu robotów zamknięto w osobnych modułach (pakietach). Każdy z tych modułów posiada swoje osobne klasy pochodzące z architektury MVP:

- **Model** jest zbiorem klas zajmujących się główną logiką dziedziny aplikacji. Model reprezentowany jest m.in przez klasy odpowiedzialne za reguły poruszania się robotów, obsługę wykonywania kolejnych kroków symulacji, algorytmy planowania trajektorii, kolejkowanie zaplanowanych ruchów, działania na wektorach (w metodzie pól potencjalnych) oraz reprezentację pól na mapie.
- **Widok** jest reprezentacją interfejsu użytkownika, który wyświetla dane i kieruje informacje o akcjach użytkownika (zdarzeniach) do prezentera. W tym wypadku instancje widoków generowane są automatycznie przez mechanizmy JavaFX na podstawie ich definicji zapisanych w plikach formatu FXML.
- **Prezenter** deleguje dane otrzymane z modelu do widoku, uprzednio przygotowując je do wyświetlenia. Jest w nim zawarta logika warstwy prezentacji.

Taka separacja warstw prezentacji od warstwy logiki umożliwia łatwe ”odpięcie” logiki modelu od interfejsu użytkownika i wykorzystanie jej do wykonania testów skuteczności metod planowania. Pozwala to na wykonanie ”przyspieszonej” symulacji poprzez sekwencyjne uruchamianie kroków symulacji tak szybko, jak to możliwe, bez oczekiwania na wyzwolenie ich przez kolejne cykle zegara. Klasy modelu były projektowane właśnie z myślą o możliwości wykorzystania ich zarówno w wizualizacji w czasie rzeczywistym, jak i w przyspieszonej symulacji w celu przeprowadzenia testów.

5.4.2 Wielowątkowość

Aplikacja uruchamia planowanie trajektorii w osobnych wątkach w tle, aby nie wpływać na wątek interfejsu użytkownika i uzyskać możliwie płynne animacje. Wymaga to synchronizacji między wątkami, jednak język Java zapewnia stosunkowo łatwą obsługę wątków i synchronizacji sekcji krytycznych. Wątki obliczeń oraz odświeżania interfejsu użytkownika są powtarzane w stałych, zadanych cyklach zegara, które nie są ze sobą zsynchronizowane (nie czekają na siebie), co daje efekt symulacji w czasie rzeczywistym, niezależnie od stanu ukończenia obliczeń.

Rozdział 6

Przeprowadzone testy

W tym rozdziale omówione zostało przeprowadzenie testów zaimplementowanych algorytmów.

Należy zaznaczyć, że wspomniane w tym rozdziale testy powinny być rozumiane jako eksperymenty przeprowadzenia symulacji planowania tras dla wielu robotów mobilnych, mające na celu zebranie statystycznych danych o przebiegu i rezultatach tych symulacji. Zatem już z założenia część tych testów może zakończyć się niepowodzeniem. Nie należy mylić tego z automatycznymi testami poprawności wykonywanymi podczas rozwijania aplikacji w ramach podejścia TDD (*Test-Driven Developmnet*), które zostały opisane w jednym z poprzednich rozdziałów (por. 5.3.4).

W ramach testów metod planowania tras wykonano pomiary skuteczności oraz wydajności w różnych środowiskach. Środowiska te były generowane w sposób losowy, dlatego z obszernych pomiarów zbierano statystyczne wyniki będące wartością średnią mierzonych wskaźników.

Wśród testowanych algorytmów znalazły się:

- Algorytm A* bez rozwiązywania kolizji (por. 4.2),
- LRA* - Local-Repair A* (por. 4.3),
- WHCA*1 - Windowed Hierarchical Cooperative A* bez dynamicznego przydzielania priorytetów, ze stałym oknem czasowym (por. 4.4),
- WHCA*2 - Windowed Hierarchical Cooperative A* z dynamicznym przydziałem priorytetów (por. 4.5),
- WHCA*3 - Windowed Hierarchical Cooperative A* z dynamicznym przydziałem priorytetów oraz skalowaniem okna czasowego (por. 4.5).

Mierzonymi wskaźnikami były:

- liczba wystąpień pomyślnego, bezkolizyjnego doprowadzenia wszystkich robotów do ich celów oraz ”skuteczność” rozumiana jako iloraz liczby udanych planowań do liczby wszystkich symulacji,
- liczba kroków symulacji (minimalny czas wykonywania akcji w rzeczywistym środowisku do momentu doprowadzenia wszystkich robotów do celu),
- złożoność obliczeniowa planowania (czas wykonywania obliczeń dla samego wyznaczania tras w ciągu całej symulacji).

6.1 Automatyczne zarządzanie symulacjami

Na potrzeby wszystkich testów, których wyniki zamieszczono w rozdziale 6, przeprowadzono razem 76 800 automatycznie zarządzanych symulacji ruchu robotów. Wykonano to dla różnych metod planowania, z różnymi parametrami i na różnych mapach oraz układach robotów.

Do automatycznego wykonywania symulacji wykorzystano bibliotekę *jUnit*. Choć w standardowym zastosowaniu służy ona do wykonywania automatycznych testów jednostkowych sprawdzających poprawność pojedynczych komponentów aplikacji, to jednak wykorzystano ją tutaj ze względu na możliwość uruchomienia istniejących fragmentów aplikacji w innym trybie. Pozwala to na wykonanie serii symulacji bez wyświetlania graficznego interfejsu użytkownika. Jednocześnie nie powoduje to jakiekolwiek ingerencji w kod źródłowy głównej aplikacji graficznego simulatorka. Takie podejście możliwe jest również dzięki zastosowaniu warstwowej architektury MVP w aplikacji (por. 5.4.1).

Przykładem automatycznego zarządzania symulacjami jest fragment aplikacji utworzony na potrzeby testów przedstawionych w rozdziale 6.3.6. W pętli dla kolejnych wartości liczby robotów (od 1 do 30) generowana jest losowa mapa z labiryntem o ustalonej wielkości. Następnie na mapie umieszczane są roboty w losowych polach i przydzielane są im losowe punkty docelowe. Stanowi to warunki początkowe dla wykonywanej symulacji. Kolejne kroki symulacji wykonywane są sekwencyjnie, w sposób ciągły, bez ograniczeń czasowych (bez oczekiwania na kolejne cykle zegarowe, jak w przypadku wizualizacji z graficznym interfejsem użytkownika). Następnie odtwarzane są te same warunki początkowe a symulacja wykonywana jest ponownie, tym razem z wykorzystaniem innych metod planowania. Wszystko to jest powtarzane 1000 razy (dla różnych losowych środowisk) a ze zmierzonych wskaźników obliczana jest wartość średnia. Liczba sytuacji, w których bezkolizyjne doprowadzenie wszystkich robotów do celu powiodło się, zapisywana jest dla każdej metody planowania osobno. Wyniki przebiegu symulacji, wyjątkowe zdarzenia oraz obliczone statystyczne wskaźniki wyświetlane są w konsoli a także zapisywane są do pliku dziennika zdarzeń.

Wykonywane symulacje ograniczone są maksymalną liczbą kroków, po przekroczeniu której symulacja jest przerwana i stwierdzane jest niepowodzenie w odnalezieniu bezkolizyjnych tras dla wszystkich robotów. Zatem sytuacja, w której tylko jeden robot nie znalazł bezkolizyjnej ścieżki do punktu docelowego, jest traktowana tak samo (jako brak rozwiązania), jak gdy żaden z robotów nie dotrze do swojego indywidualnego celu. Ograniczenie liczby kroków symulacji jest konieczne ze względu na fakt, że w niektórych algorytmach wyznaczania tras (np. LRA*) mogą wystąpić nieskończone cykle zaplanowanych akcji. Wartość maksymalnej liczby kroków *stepsLimit* w symulacji została przyjęta arbitralnie na podstawie obserwacji liczby kroków potrzebnych do pomyślnego doprowadzenia robotów do celów przy zmiennej liczbie robotów oraz rozmiarze mapy, wynosi ona:

$$stepsLimit = (w + h) * r \quad (6.1)$$

gdzie:

w - szerokość mapy wyrażona w liczbie pól

h - wysokość mapy wyrażona w liczbie pól

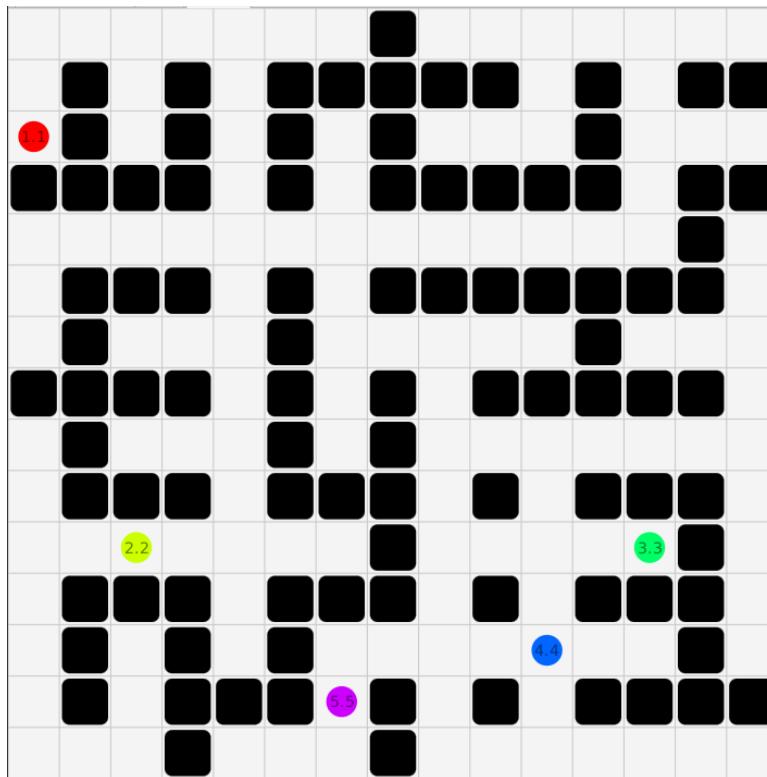
r - liczba robotów na mapie

6.2 Środowiska testowe

Część testów została przeprowadzona na czterech typach losowych środowisk, którym dla uproszczenia zapisu nadano nazwy:

- **M-15x15-5R** - mapa rozmiaru 15×15 z wygenerowanym labiryntem, 5 robotów na mapie (por. rys. 6.1),
- **M-15x15-10R** - mapa rozmiaru 15×15 z wygenerowanym labiryntem, 10 robotów na mapie (por. rys. 6.2),
- **M-35x35-5R** - mapa rozmiaru 35×35 z wygenerowanym labiryntem, 5 robotów na mapie (por. rys. 6.3),
- **E-15x15-40R** - mapa rozmiaru 15×15 bez przeszkód, 40 robotów na mapie (por. rys. 6.4).

Warto zaznaczyć, że testowane środowiska są bardzo trudnymi warunkami dla metod planowania tras, dlatego skuteczność badanych algorytmów może wydawać się względnie niska,

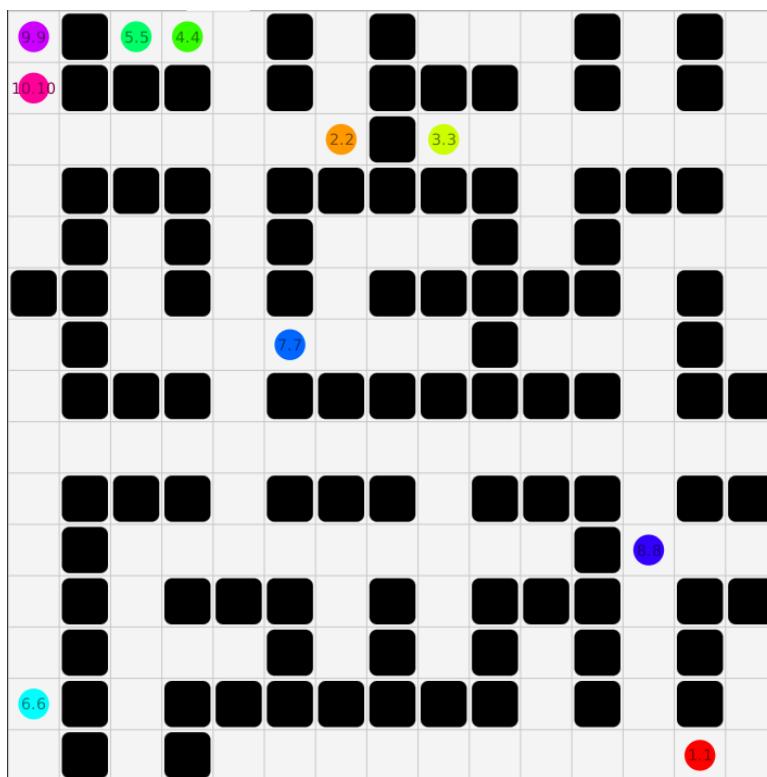


Rysunek 6.1: Przykładowe środowisko typu M-15x15-5R - mapa 15×15 z wygenerowanym labiryntem, z 5 robotami w losowych położeniach

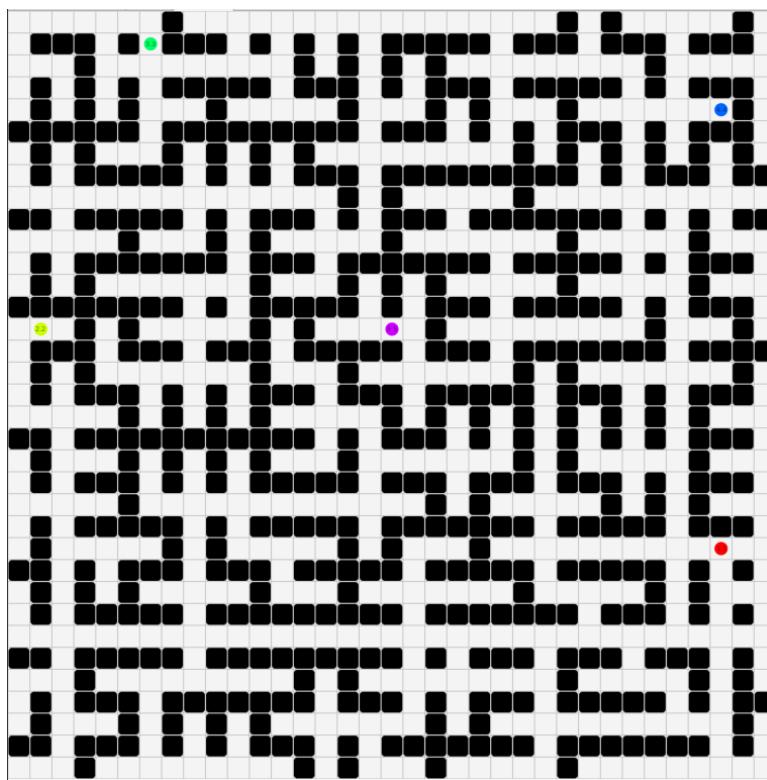
podczas gdy użycie tych samych metod na innych mapach mogłoby skutkować dużo wyższą skutecznością.

Dla każdego typu środowiska za każdym razem generowana jest nowa, losowa mapa. Również położenie początkowe i docelowe robotów jest lososowane. Zatem w każdej symulacji wykorzystywane jest inne środowisko, chyba, że porównywane są między sobą różne metody. Wtedy rekonstruowane są te same warunki początkowe, aby przeprowadzić symulację ponownie z wykorzystaniem innej metody planowania.

Każdy z robotów otrzymuje losowe położenie początkowe. Jest to zawsze pole, na którym nie znajduje się przeszkoda, ani nie ma na nim innego robota. Punkty docelowe także są losowane. Mogą to być pola, na których obecnie znajduje się jakiś robot, natomiast nie może to być punkt docelowy należący do innego robota, gdyż w przeciwnym wypadku uniemożliwiłoby to znalezienie rozwiązania, niezależnie od metody planowania.



Rysunek 6.2: Przykładowe środowisko typu $M-15 \times 15-10R$ - mapa 15×15 z wygenerowanym labiryntem, z 10 robotami w losowych położeniach



Rysunek 6.3: Przykładowe środowisko typu $M-35 \times 35-5R$ - mapa 35×35 z wygenerowanym labiryntem, z 5 robotami w losowych położeniach



Rysunek 6.4: Przykładowe środowisko typu E-15x15-40R - mapa 15×15 bez przeszkód, z 40 robotami w losowych położeniach

6.3 Wyniki testów

6.3.1 Częstotliwość występowania potencjalnych kolizji

Na początku przeprowadzamy testy częstotliwości występowania potencjalnych kolizji w badanych środowiskach, aby ocenić znaczenie tego problemu. Dla każdego robota wykonujemy planowanie trasy za pomocą prostego algorytmu A*. Następnie przeprowadzamy symulację ruchu. W momencie wykrycia kolizji robotów zatrzymujemy symulację i zliczamy ilość takich sytuacji. W ten sposób mierzymy, jak często występują kolizje między robotami, jeśli planowanie odbywa się za pomocą algorytmu wyznaczania najkrótszych tras (bez unikania kolizji). Słuszne jest założenie, że algorytm A* powinien zawsze znaleźć drogę do celu (z pominieciem pozostałych agentów), gdyż w tego typu środowiskach zawsze istnieje połączenie między dwoma dowolnymi polami na mapie 4.1.

W tabeli 6.1 przedstawiono wyniki eksperymentów. Skuteczność oznacza w tym przypadku procentową liczbę symulacji, w których ruch wzduż zaplanowanych tras odbył się bez żadnych kolizji i wszystkie roboty zostały doprowadzone do celu. Kolumna "Przeprowadzone symulacje" wyraża liczbę losowo wygenerowanych środowisk określonego typu.

*Tabela 6.1: Częstotliwość występowania kolizji w środowiskach zmierzona za pomocą skuteczności algorytmu A**

Typ środowiska	Przeprowadzone symulacje	Skuteczność	Występowanie kolizji
M-15x15-5R	1000	10%	90%
M-15x15-10R	1000	1%	99%
M-35x35-5R	1000	14%	86%
E-15x15-40R	1000	0%	100%

W tym teście przeprowadzono razem 4 000 symulacji.

Uzyskane niskie wskaźniki skuteczności potwierdzają, że w tego typu środowiskach, problem występowania kolizji jest bardzo istotny i sam prosty algorytm A* nie wystarcza, aby poradzić sobie z bezkolizyjnym doprowadzeniem wszystkich robotów do celów.

6.3.2 Wpływ wielkości okna czasowego

Zbadano skuteczność metody WHCA*1 (bez dynamicznego przydziału priorytetów) w zależności od wielkości okna czasowego, które to pozostaje stałe w trakcie trwania jednej symulacji. Dla każdego badanego typu środowiska wylosowano 100 map, dla których powtórzono eksperymenty w tych samych warunkach, ale z różnymi rozmiarami okna czasowego od 1 do 30. Dla rozmiaru okna równego 1 skuteczność metody zawsze jest zerowa, gdyż zaplanowane dla robotów ścieżki są zawsze długości 1, a pierwszym punktem ścieżki jest zawsze aktualna pozycja robota, przez co roboty pozostają w tym samym miejscu. Uzyskane wyniki dla każdego środowiska przedstawiono w tabeli 6.2 oraz na wykresach 6.5, 6.6, 6.7 i 6.8.

Tabela 6.2: Wpływ wielkości okna czasowego na skuteczność metody WHCA*1 w różnych typach środowisk


Rozmiar okna czasowego	M-15x15-5R	M-15x15-10R	M-35x35-5R	E-15x15-40R
1	0%	0%	0%	0%
2	9%	0%	27%	0%
3	11%	0%	30%	0%
4	11%	0%	43%	0%
5	16%	0%	43%	31%
6	21%	0%	48%	65%
7	30%	0%	52%	84%
8	35%	5%	61%	93%
9	42%	5%	61%	96%
10	42%	7%	61%	98%
11	46%	10%	69%	100%
12	53%	12%	74%	100%
13	53%	12%	75%	100%
14	61%	12%	75%	100%
15	61%	20%	82%	100%
16	62%	20%	82%	100%
17	63%	22%	90%	100%
18	64%	23%	90%	100%
19	64%	23%	92%	100%
20	65%	26%	95%	100%
21	65%	26%	100%	100%
22	65%	26%	100%	100%
23	67%	30%	100%	100%
24	67%	33%	100%	100%
25	67%	33%	100%	100%
26	69%	33%	100%	100%
27	69%	33%	100%	100%
28	69%	35%	100%	100%
29	69%	35%	100%	100%
30	69%	35%	100%	100%

W tych testach przeprowadzono razem 400 symulacji.


Zgodnie z oczekiwaniami skuteczność metody WHCA*1 rośnie monotonicznie wraz ze wzrostem rozmiaru okna czasowego.

6.3.3 Skuteczność LRA* i WHCA*3


W kolejnym eksperymencie przeprowadzono serie testów mających na celu porównanie skuteczności metody LRA* oraz WHCA*3 z dynamicznym przydziałem priorytetów. Mapy generowane były losowo, natomiast dla każdego środowiska symulacja została wykonana dwukrotnie:




Rysunek 6.5: Wykres skuteczności metody WHCA* w zależności od rozmiaru okna czasowego dla środowiska typu M-15x15-5R



Rysunek 6.6: Wykres skuteczności metody WHCA* w zależności od rozmiaru okna czasowego dla środowiska typu M-15x15-10R



Rysunek 6.7: Wykres skuteczności metody WHCA* w zależności od rozmiaru okna czasowego dla środowiska typu M-35x35-5R



Rysunek 6.8: Wykres skuteczności metody WHCA* w zależności od rozmiaru okna czasowego dla środowiska typu E-15x15-40R

raz wykonując planowanie tras metodą WHCA*3 a następnie metodą LRA* po odtworzeniu tych samych warunków początkowych. Dla każdej takiej symulacji zliczano, ile razy obie metody pomyślnie doprowadziły wszystkie roboty do celu, ile razy powiodła się tylko metoda WHCA*3, ile razy tylko metoda LRA*, oraz ile razy żadna z metod nie zakończyła się powodzeniem. Umożliwiło to porównanie skuteczności metod w dokładnie tych samym warunkach. Wyniki przedstawiono w tabeli 6.3. Dla każdego typu środowiska wygenerowano 1000 map z różnymi układami robotów. W ramach tych testów przeprowadzono razem 8 000 symulacji.

Tabela 6.3: Porównanie skuteczności LRA* i WHCA*3 w tych samych warunkach

Typ środowiska	Powodzenie WHCA*3 i LRA*	Powodzenie tylko WHCA*3	Powodzenie tylko LRA*	Brak powodzenia
M-15x15-5R	23,0%	66,7%	0%	10,3%
M-15x15-10R	1,2%	64,0%	0%	34,8%
M-35x35-5R	51,3%	47,1%	0%	1,6%
E-15x15-40R	82,3%	17,7%	0%	0%

Warto zaznaczyć, że niepowodzenie metody WHCA*3 może wynikać zarówno z ograniczeń metody, jak i z przypadkowego wylosowania układu przeszkód i robotów, który sam w sobie jest niemożliwy do rozwiązania. Należy także podkreślić, że spośród wszystkich środowisk nie zdarzyło się, aby metoda LRA* dała lepsze rozwiązanie od WHCA*3. Potwierdza to oczekiwania w stosunku do metody WHCA*3, która jest znacznie bardziej zaawansowana od metody LRA*.

6.3.4 Porównanie wariantów WHCA*

W kolejnych testach porównano skuteczność różnych wariantów metody WHCA*: WHCA*1, WHCA*2 (z dynamicznym przydziałem priorytetów), WHCA*3 (z dynamicznym przydziałem priorytetów i skalowaniem okna czasowego) oraz metodę LRA*. Symulacje powtarzano dla każdej metody, odtwarzając te same warunki początkowe (układ map, robotów i punktów docelowych). Wyniki przedstawiono w tabeli 6.4. Dla każdego typu środowiska wygenerowano 1000 map z różnymi układami robotów. W ramach tych testów przeprowadzono razem 16 000 simulacji.


Tabela 6.4: Porównanie skuteczności metod LRA*, WHCA*1, WHCA*2, WHCA*3

Typ środowiska	Skuteczność LRA*	Skuteczność WHCA*1	Skuteczność WHCA*2	Skuteczność WHCA*3
M-15x15-5R	22,5%	26,3%	54,6%	87%
M-15x15-10R	0,2%	3,4%	48,9%	54,5%
M-35x35-5R	52,7%	40,1%	69,7%	98,6%
E-15x15-40R	76,7%	99,5%	100%	100%


Wyniki potwierdzają oczekiwana nierówność zachodzącą pomiędzy średnimi skutecznościami poszczególnych metod dla każdego z badanych typów środowisk.

6.3.5 Wpływ rozmiaru mapy


Dla stałej liczby robotów (rowniej 5) przeprowadzono testy wpływu rozmiaru mapy na skuteczność metod LRA*, WHCA*1, WHCA*2 oraz WHCA*3. Dla każdej z metod zmierzono także średnią liczbę kroków symulacji potrzebną do doprowadzenia wszystkich robotów do celów (dla symulacji zakończonych powodzeniem) oraz złożoność obliczeniową samego planowania (średni czas wykonywania obliczeń dla wyznaczania tras w ciągu całej symulacji). Symulacje przeprowadzono na kwadratowych mapach. Rozmiar mapy zmieniał się w zakresie od 3×3 do 40×40 (w przypadku mapy z labiryntem) oraz w zakresie od 3×3 do 25×25 (w przypadku pustej mapy), generując 100 losowych układów dla każdego rozmiaru mapy, następnie dla każdego takiego układu wykonano symulację każdą z 4 badanych metod. Wszystko powtórzono zarówno dla map z wygenerowanym labiryntem, jak i dla pustych map bez umieszczonych przeszkód. W ramach tych testów przeprowadzono razem 24 400 symulacji. Wyniki przedstawiono na wykresach 6.9, 6.10, 6.11, 6.12, 6.13, 6.14.




Rysunek 6.9: Wykres skuteczności metod LRA*, WHCA*1, WHCA*2 i WHCA*3 w zależności od rozmiaru mapy, z wygenerowanym labiryntem




Rysunek 6.10: Wykres średniej liczby kroków symulacji dla metod LRA*, WHCA*1, WHCA*2 i WHCA*3 w zależności od rozmiaru mapy, z wygenerowanym labiryntem




Rysunek 6.11: Wykres czasu planowania dla metod LRA*, WHCA*1, WHCA*2 i WHCA*3 w zależności od rozmiaru mapy, z wygenerowanym labiryntem




Rysunek 6.12: Wykres skuteczności metod LRA*, WHCA*1, WHCA*2 i WHCA*3 w zależności od rozmiaru mapy, bez przeszkód na mapie



Rysunek 6.13: Wykres średniej liczby kroków symulacji dla metod LRA*, WHCA*1, WHCA*2 i WHCA*3 w zależności od rozmiaru mapy, bez przeszkód na mapie



Rysunek 6.14: Wykres czasu planowania dla metod LRA*, WHCA*1, WHCA*2 i WHCA*3 w zależności od rozmiaru mapy, bez przeszkód na mapie




Rysunek 6.15: Wykres skuteczności metod LRA*, WHCA*1, WHCA*2 i WHCA*3 w zależności od liczby robotów, z wygenerowanym labiryntem

6.3.6 Wpływ liczby robotów


Dla stałego rozmiaru mapy przeprowadzono testy wpływu liczby robotów na skuteczność metod LRA*, WHCA*1, WHCA*2 oraz WHCA*3. Dla każdej z metod zmierzono także średnią liczbę kroków symulacji potrzebną do doprowadzenia wszystkich robotów do celów (dla symulacji zakończonych powodzeniem) oraz złożoność obliczeniową samego planowania (średni czas wykonywania obliczeń dla wyznaczania tras w ciągu całej symulacji). Liczbę robotów zwiększano od 1 do 30, generując 100 losowych układów dla każdej liczby robotów, następnie dla każdego takiego układu wykonano symulację każdą z 4 badanych metod. Wszystko powtórzono zarówno dla map z wygenerowanym labiryntem o rozmiarze 15×15 , jak i dla pustych map bez umieszczonych przeszkód o rozmiarze 6×6 . W ramach tych testów przeprowadzono razem 24 000 symulacji. Wyniki przedstawiono na wykresach 6.15, 6.16, 6.17, 6.18, 6.19, 6.20.

Na wykresach średniej liczby kroków symulacji oraz czasu planowania widoczne są "ucięte" serie pomiarów. Oznacza to zerową skuteczność w tych obszarach i tym samym brak możliwości wyznaczenia tych wartości z powodu zerowej liczby pomyślnie zakończonych symulacji dla danej metody planowania.


Zgodny z oczekiwaniami jest niewątpliwy fakt, iż zwiększenie liczby robotów utrudnia znalezienie rozwiązania, zmniejszając skuteczność metod.




Rysunek 6.16: Wykres średniej liczby kroków symulacji dla metod LRA*, WHCA*1, WHCA*2 i WHCA*3 w zależności od liczby robotów, z wygenerowanym labiryntem




Rysunek 6.17: Wykres czasu planowania dla metod LRA*, WHCA*1, WHCA*2 i WHCA*3 w zależności od liczby robotów, z wygenerowanym labiryntem



Rysunek 6.18: Wykres skuteczności metod LRA*, WHCA*1, WHCA*2 i WHCA*3 w zależności od liczby robotów, bez przeszkód na mapie



Rysunek 6.19: Wykres średniej liczby kroków symulacji dla metod LRA*, WHCA*1, WHCA*2 i WHCA*3 w zależności od liczby robotów, bez przeszkód na mapie



Rysunek 6.20: Wykres czasu planowania dla metod LRA*, WHCA*1, WHCA*2 i WHCA*3 w zależności od liczby robotów, bez przeszkód na mapie


6.3.7 Metoda pól potencjałowych

Metoda pól potencjałowych zaimplementowana w aplikacji okazała się mieć bardzo niską skuteczność w doprowadzeniu do celu nawet jednego robota. Tym bardziej nie nadaje się do skutecznego rozwiązania skomplikowanego zagadnienia znalezienia bezkolizyjnych tras dla wielu robotów. Niska skuteczność metody wynika m.in. z charakteru wygenerowanych map, w których robot bardzo często napotyka na lokalne minimum, z którego nie potrafi się wydostać. Przykład uwięzienia robota w takiej ”studni potencjału” został przedstawiony na rysunku 6.21.

6.4 Dyskusja wyników

Przeprowadzenie eksperymentów, które pozwoliłyby uzyskać niepodważalne wnioski, jest bardzo trudnym zadaniem w przypadku metod planowania tras. Należy pamiętać, że porównanie wyników badanych algorytmów możliwe jest jedynie w kontekście indywidualnej, pojedynczej konfiguracji przeszkód i robotów na mapie. Zatem utrudnione jest otrzymanie ogólnego wniosku, który byłby prawdziwy dla wszystkich możliwych układów robotów. Z tego powodu testy zostały przeprowadzone w dużej ilości, w losowych środowiskach, a następnie posłużono się statystyką w celu generalizacji uzyskanych rezultatów.

Warto zaznaczyć, że nie dysponujemy zupełną metodą planowania tras, która byłaby w stanie znaleźć zawsze optymalne rozwiązanie lub obiektywnie stwierdzić, że żadne rozwiązanie nie istnieje. Niestety brak takiego źródła referencyjnego nie pozwala w pełni ocenić skuteczności



Rysunek 6.21: Robot uwieziony w studni potencjału. Zerowa siła wypadkowa nie pozwala mu dotrzeć do celu.

badanych metod. W szczególności nie można stwierdzić, czy testowana metoda planowania nie uzyskała rozwiązania z powodu własnych ograniczeń, czy też z powodu tego, że wylosowany układ przeszkód i robotów był sam w sobie niemożliwy do rozwiązania. Możliwe natomiast jest porównanie rezultatów różnych metod planowania w tych samych warunkach początkowych, co może dostarczyć pewnych wniosków.

Należy pamiętać, że ze względu na wybraną technologię realizacji (Java), pomiar czasu obliczeń może być obarczony pewnymi błędami wynikającymi z narzutu wirtualnej maszyny JVM oraz działania mechanizmu zwalniania pamięci przez Garbage Collector, co wstrzymuje aplikację. Na takie zdarzenie nie ma wpływu programista, a może ono wystąpić w dowolnym momencie działania aplikacji, powodując przekłamania zmierzzonego czasu.

Wyniki testów potwierdziły oczekiwania w stosunku do skuteczności porównywanych metod. Najwyższą skuteczność w planowaniu bezkolizyjnych tras dla wielu robotów uzyskała autorska metoda WHCA*³. Brak zastosowania skalowania okna czasowego skutkował niższą skutecznością metody WHCA*². W badanych środowiskach najgorzej wypadły metody LRA* oraz WHCA*¹.

Na dużych mapach oraz przy większej liczbie robotów czas wykonywania obliczeń planowania tras przez metodę WHCA*³ jest stosunkowo długi. Obserwacja czasu obliczeń pozwala stwierdzić, że złożoność WHCA*³ ma charakter wykładniczy, co także potwierdza oczekiwania.

Zastosowanie do wyznaczania wartości heurystyki innych, wydajniejszych algorytmów takich jak RRA*, D* Lite lub D* Extra Lite, mogłoby zmniejszyć czas obliczeń, przyspieszając proces planowania bezkolizyjnych tras, w szczególności na większych mapach.

Rozdział 7

Podsumowanie

TODO zebrać wnioski

Bibliografia

- [1] Bennewitz M.; Burgard W.; Thrun S. *Optimizing Schedules for Prioritized Path Planning of Multi-Robot Systems*. 2001.
- [2] Cap M.; Novak P.; Vokrinek J.; Pechoucek M. *Asynchronous Decentralized Algorithm for Space-Time Cooperative Pathfinding*. Workshop Proceedings of the European Conference on Artificial Intelligence (ECAI 2012), 2012.
- [3] Duc L. M.; Sidhu A. S.; Chaudhari N. S. *Hierarchical Pathfinding and AI-Based Learning Approach in Strategy Game Design*. International Journal of Computer Games Technology, 2008.
- [4] Geramifard A.; Chubak P. *Efficient Cooperative Path-Planning*. Computing Science Department, University of Alberta, 2005.
- [5] Hart P. E.; Nilsson N. J.; Raphael B. *A Formal Basis for the Heuristic Determination of Minimum Cost Paths*. IEEE Transactions on Systems Science and Cybernetics SSC4, 1968.
- [6] Koenig S.; Likhachev M. *D* Lite*. Proceedings of the AAAI Conference of Artificial Intelligence, 2002.
- [7] Latombe J. *Robot Motion Planning*. Boston, MA: Kluwer Academic, 1991.
- [8] Mówinski K.; Roszkowska E. *Sterowanie hybrydowe ruchem robotów mobilnych w systemach wielorobotycznych*. Postępy Robotyki, 2016.
- [9] Przybylski M.; Putz B. *D* Extra Lite: A Dynamic A* With Search-Tree Cutting and Frontier-Gap Repairing*. International Journal of Applied Mathematics and Computer Science, 2017.
- [10] Siemiątkowska B. *Uniwersalna metoda modelowania zachowań robota mobilnego wykorzystująca architekturę uogólnionych sieci komórkowych*. Oficyna Wydawnicza Politechniki Warszawskiej, 2009.

- [11] Silver D. *Cooperative Pathfinding*. Proceedings of the First Artificial Intelligence and Interactive Digital Entertainment Conference, 2005.
- [12] Standley T.; Korf R. *Complete Algorithms for Cooperative Pathfinding Problems*. Proceedings of the Twenty-Second International Joint Conference on Artificial Intelligence, 2011.
- [13] Toresson A. *Real-time Cooperative Pathfinding*. 2010.
- [14] Zhu Q.; Yan Y.; Xing Z. *Robot Path Planning Based on Artificial Potential Field Approach with Simulated Annealing*. Intelligent Systems Design and Applications, 2006.
- [15] A* pathfinding for beginners. <http://homepages.abdn.ac.uk/f.guerin/pages/teaching/CS1013/practicals/aStarTutorial.htm>. Dostęp: 2018-01-02.
- [16] Amazon warehouse demand devours robots and workers. https://www.roboticsbusinessreview.com/supply-chain/amazon_warehouse_demand_devours_robots_and_workers. Dostęp: 2018-01-05.
- [17] Dokumentacja API Java Platform, Standard Edition 8. <https://docs.oracle.com/javase/8/docs/api/>. Dostęp: 2018-01-30.
- [18] Dokumentacja API JavaFX 8. <https://docs.oracle.com/javase/8/javafx/api/toc.htm>. Dostęp: 2018-01-30.
- [19] Dokumentacja biblioteki SpringBoot JavaFx 8.0 Support. <https://springboot-javafx-support.readthedocs.io/en/latest/>. Dostęp: 2018-01-30.
- [20] Dokumentacja Spring Boot. <https://docs.spring.io/spring-boot/docs/current-SNAPSHOT/reference/htmlsingle/>. Dostęp: 2018-01-30.
- [21] Porównanie wzorców architektonicznych MVC i MVP. <https://www.techyourchance.com/mvp-mvc-android-1/>. Dostęp: 2018-01-05.
- [22] Projekt aplikacji symulatora na portalu GitHub. <https://github.com/igrek51/coop-pathfinder>. Dostęp: 2018-02-09.
- [23] Choset H. Robotic motion planning: Potential functions. https://www.cs.cmu.edu/~motionplanning/lecture/Chap4-Potential-Field_howie.pdf. Dostęp: 2018-01-02.
- [24] Roboty TUG i HOMER firmy Aethon. <http://www.aethon.com/tug/tughealthcare/>. Dostęp: 2018-01-02.

- [25] Searching using A*. <http://web.mit.edu/eranki/www/tutorials/search/>. Dostęp: 2018-01-02.
- [26] Wsparcie dla JavaFX od Oracle. <http://www.oracle.com/technetwork/java/javafx/overview/faq-1446554.html#6>. Dostęp: 2018-01-02.

Wykaz skrótów

API	Application Programming Interface
CA*	Cooperative A*
HCA*	Hierarchical Cooperative A*
IoC	Inversion of Control
JDK	Java Development Kit
JVM	Java Virtual Machine
LRA*	Local Repair A*
MAS	Multi-Agent System
MVP	Model-View-Presenter
RRA*	Reverse Resumable A*
RTS	Real Time Strategy
TDD	Test-driven Development
WHCA*	Windowed Hierarchical Cooperative A*

Spis rysunków

1.1	Przykładowe środowisko z dużą liczbą przeszkode (czarne kwadraty) i rozmieszczonymi robotami (kolorowe koła). Źródło: własna implementacja oprogramowania symulacyjnego	16
1.2	Roboty Kiva pracujące w magazynie firmy Amazon. Źródło: [16]	17
1.3	Popularny problem zakleszczania się jednostek w wąskich gardłach występujący w grach typu RTS. Źródło: gra komputerowa Age of Empires II Forgotten Empires	18
2.1	Zasada działania metody pól potencjałowych. Dodatni ładunek q_{start} reprezentuje robota. Przyciągany jest w stronę ujemnego ładunku celu q_{goal} , zaś odpychany jest od dodatnio naładowanej przeszkode. Źródło: [23]	21
2.2	Ciągła przestrzeń mapy zdyskretyzowana do siatki pól. Źródło: edytor map z gry Warcraft III.	21
2.3	Sytuacja, w której żadne rozwiązanie nie zostanie znalezione, stosując planowanie uwzględniające priorytety, jeśli robot 1 ma wyższy priorytet niż robot 2. Źródło: [1]	22
2.4	a) Niezależne planowanie optymalnych tras dla 2 robotów; b) suboptymalne rozwiązanie, gdy robot 1 ma wyższy priorytet; c) rozwiązanie, gdy robot 2 ma wyższy priorytet. Źródło: [1]	23
3.1	Ilustracja wyznaczania działania przez A*. Każdy odwiedzony węzeł wskazuje na swojego rodzica, co umożliwia późniejszą rekonstrukcję drogi. Źródło: [15] . .	27
3.2	Dwie jednostki kooperacyjnie poszukujące tras. (A) Pierwsza jednostka znajduje ścieżkę i zaznacza ją w tablicy rezerwacji. (B) Druga jednostka znajduje ścieżkę, uwzględniając istniejące rezerwacje pól, również zaznaczając ją w tablicy rezerwacji. Źródło: [11]	31
3.3	Tablica rezerwacji jest współdzielona między wszystkimi agentami. Jej rozmiar powinien być odpowiednio dopasowany do agentów o różnych prędkościach. Źródło: [11]	31

4.1	Kolejne etapy generowania labiryntu: (a) Zaznaczenie co drugiego pola jako wolne i wybór ziarna rozrostu labiryntu. (b) Wylosowanie i łączenie kolejnego wierzchołka poprzez "wyburzanie" przeszkód na drodze (c) Wynikowa mapa pochodząca z generatora	37
4.2	Przykładowy labirynt rozmiaru 75×75 pochodzący z zaprojektowanego generatora map	39
4.3	Przykładowa ścieżka wyznaczona przez zaimplementowany w aplikacji algorytm A*. Kolorowe koło reprezentuje robota, linia łamana - wyznaczoną ścieżkę, czarne kwadraty - przeszkody.	42
4.4	Przykład układu z powtarzającym się cyklem akcji planowanych przez metodę LRA*: (a) Dwa roboty wyznaczają niezależnie drogi do swoich celów. (b) Chcąc uniknąć zderzenia w wąskim przejściu po lewej stronie, roboty wyznaczają trajektorie przechodzące przez alternatywną ścieżkę po prawej stronie, gdzie ponownie dojdzie do przecięcia się trajektorii.	43
4.5	Przykład symulacji ruchu robotów metodą LRA* na dużej mapie z dużą liczbą robotów	44
4.6	Przykładowa sytuacja "przepuszczania się" robotów uzyskana metodą WHCA*:1: (a) Wyznaczona trasa przez robota 2 koliduje z aktualnym położeniem robota 1, który dotarł już do celu. (b) Robot 1 schodzi z drogi robotowi 2, ukrywając się we "wnęce". (c) Robot 2 może bezkolizyjnie dotrzeć do celu. Następnie robot 1 może powrócić do celu.	48
5.1	Zrzut ekranu aplikacji w trakcie wizualizacji metody pól potencjałowych.	55
5.2	Zrzut ekranu aplikacji w trakcie wizualizacji metody Local-Repair A*.	56
5.3	Zrzut ekranu aplikacji w trakcie wizualizacji metody Windowed Hierarchical Cooperative A*.	58
5.4	Zrzut ekranu środowiska deweloperskiego IntelliJ IDEA Ultimate	61
5.5	Relacja pomiędzy poszczególnymi elementami wzorca architektonicznego Model-View-Presenter. Źródło: [21]	62
6.1	Przykładowe środowisko typu M-15x15-5R - mapa 15×15 z wygenerowanym labiryntem, z 5 robotami w losowych położeniach	68
6.2	Przykładowe środowisko typu M-15x15-10R - mapa 15×15 z wygenerowanym labiryntem, z 10 robotami w losowych położeniach	69
6.3	Przykładowe środowisko typu M-35x35-5R - mapa 35×35 z wygenerowanym labiryntem, z 5 robotami w losowych położeniach	69

6.4	Przykładowe środowisko typu E-15x15-40R - mapa 15×15 bez przeszkód, z 40 robotami w losowych położeniach	70
6.5	Wykres skuteczności metody WHCA* w zależności od rozmiaru okna czasowego dla środowiska typu M-15x15-5R	73
6.6	Wykres skuteczności metody WHCA* w zależności od rozmiaru okna czasowego dla środowiska typu M-15x15-10R	73
6.7	Wykres skuteczności metody WHCA* w zależności od rozmiaru okna czasowego dla środowiska typu M-35x35-5R	73
6.8	Wykres skuteczności metody WHCA* w zależności od rozmiaru okna czasowego dla środowiska typu E-15x15-40R	74
6.9	Wykres skuteczności metod LRA*, WHCA*1, WHCA*2 i WHCA*3 w zależności od rozmiaru mapy, z wygenerowanym labiryntem	76
6.10	Wykres średniej liczby kroków symulacji dla metod LRA*, WHCA*1, WHCA*2 i WHCA*3 w zależności od rozmiaru mapy, z wygenerowanym labiryntem	76
6.11	Wykres czasu planowania dla metod LRA*, WHCA*1, WHCA*2 i WHCA*3 w zależności od rozmiaru mapy, z wygenerowanym labiryntem	77
6.12	Wykres skuteczności metod LRA*, WHCA*1, WHCA*2 i WHCA*3 w zależności od rozmiaru mapy, bez przeszkód na mapie	77
6.13	Wykres średniej liczby kroków symulacji dla metod LRA*, WHCA*1, WHCA*2 i WHCA*3 w zależności od rozmiaru mapy, bez przeszkód na mapie	78
6.14	Wykres czasu planowania dla metod LRA*, WHCA*1, WHCA*2 i WHCA*3 w zależności od rozmiaru mapy, bez przeszkód na mapie	78
6.15	Wykres skuteczności metod LRA*, WHCA*1, WHCA*2 i WHCA*3 w zależności od liczby robotów, z wygenerowanym labiryntem	79
6.16	Wykres średniej liczby kroków symulacji dla metod LRA*, WHCA*1, WHCA*2 i WHCA*3 w zależności od liczby robotów, z wygenerowanym labiryntem	80
6.17	Wykres czasu planowania dla metod LRA*, WHCA*1, WHCA*2 i WHCA*3 w zależności od liczby robotów, z wygenerowanym labiryntem	80
6.18	Wykres skuteczności metod LRA*, WHCA*1, WHCA*2 i WHCA*3 w zależności od liczby robotów, bez przeszkód na mapie	81
6.19	Wykres średniej liczby kroków symulacji dla metod LRA*, WHCA*1, WHCA*2 i WHCA*3 w zależności od liczby robotów, bez przeszkód na mapie	81
6.20	Wykres czasu planowania dla metod LRA*, WHCA*1, WHCA*2 i WHCA*3 w zależności od liczby robotów, bez przeszkód na mapie	82
6.21	Robot uwięziony w studni potencjału. Zerowa siła wypadkowa nie pozwala mu dotrzeć do celu.	83

Spis tabel

4.1	Możliwe przejścia robota do sąsiednich węzłów z węzła (x, y, t)	45
6.1	Częstotliwość występowania kolizji w środowiskach zmierzona za pomocą skuteczności algorytmu A*	71
6.2	Wpływ wielkości okna czasowego na skuteczność metody WHCA*1 w różnych typach środowisk	72
6.3	Porównanie skuteczności LRA* i WHCA*3 w tych samych warunkach	74
6.4	Porównanie skuteczności metod LRA*, WHCA*1, WHCA*2, WHCA*3	75

Spis załączników

Na załączonej do pracy płycie CD znajdują się następujące treści:

- Niniejsza praca w formacie PDF – plik
Praca/Praca_Magisterska_Ireneusz_Szulc.pdf.
- Archiwum zawierające kody źródłowe programu symulacyjnego – plik
Kody_źródłowe/coop-pathfinder.zip